

第八章 图像分割

整体等于其部分之和。

——欧几里得

整体大于其部分之和。

——*Max Wertheimer*

8.1 概述和分类

- 图像分割：从图像中按一定规则划出感兴趣的部分或区域（称为目标或前景）
 - 图像分割是图像分析、图像识别的关键一步
 - 必须针对特定的分割要求、图像性质采用或设计不同的分割算法
 - 图像分割基于像素的二个基本特性：
 - 1.同一目标内有相似性
 - 2.不同目标间，也即在目标的边界上，纹理有不连续性
 - 分割算法可据此分为
 - 基于边界的算法：利用区域间纹理的不连续性
 - 基于区域的算法：利用区域内纹理的相似性

图像分割的定义

- 令 R 表示整幅图像，图像分割可以看做是把 R 分成为 n 个子区域 $R_1, R_2, R_3, \dots, R_n$ 的过程，满足：


- (a) $\bigcup_{i=1}^n R_i = R$; 分割必须完全；
- (b) R_i 是一个联通集, $i = 1, 2, \dots, n$; 区域中的点必须以某种方式连接
- (c) $R_i \cap R_j = \emptyset$, 对于所有 i 和 j , $i \neq j$; 区域之间必须不相交
- (d) $Q(R_i) = TRUE$, $i = 1, 2, \dots, n$; 分割后的区域点必须满足某种属性
- (e) $Q(R_i \cup R_j) = FALSE$, 对于任何 R_i 和 R_j 的邻接区域。

其中， $Q(R_i)$ 是定义在集合 R_i 的点上的一个逻辑属性。

两个邻接区域在属性 Q 意义上必须不同

基于边缘和区域的不同分割示例

基于不连续性的分割
(梯度)



基于相似性的分割
(方差)

a b c
d e f

FIGURE 10.1 (a) Image containing a region of constant intensity. (b) Image showing the boundary of the inner region, obtained from intensity discontinuities. (c) Result of segmenting the image into two regions. (d) Image containing a textured region. (e) Result of edge computations. Note the large number of small edges that are connected to the original boundary, making it difficult to find a unique boundary using only edge information. (f) Result of segmentation based on region properties.

- 图像分割过程中可采用不同的策略
 - 图像分割又可分为并行算法和串行算法
 - 并行算法中，所有的判断和决定都可独立地、同时地进行
 - 串行算法中，前面处理的结果可被后继的处理过程所利用
 - 基于边界（**boundary**）和基于区域(**region**)的算法都可以是并行(**parallel**)或串行的(**serial**)：
 - (1)并行边界（**PB**）
 - (2)串行边界（**SB**）
 - (3)并行区域（**PR**）
 - (4)串行区域（**SR**）

这些算法也可组合成复杂算法

- 图像分割应该考虑的问题

- 应该利用景物的总体知识和先验信息
- 尽可能提高图像可用性：
 - 对环境进行适度的控制（如改善成像条件、环境、光照及其方向、传感器角度等）
 - 选择合适的传感器（如可见光、低照度、日夜二用、红外）

- 图像分割算法应针对具体问题而设计

- 对分割效果的评价也没有简单的准则



8.2 点、线和边缘检测



□ 基本原理

■ 一阶导数

$$\frac{\partial f}{\partial x} = f'(x) = f(x+1) - f(x)$$

■ 二阶导数

$$\frac{\partial^2 f}{\partial^2 x} = f''(x) = f(x+1) - 2f(x) + f(x-1)$$




■ 观察结论：

- ❑ 1. 一阶导数通常产生较粗的边缘；
- ❑ 2. 二阶导数对精细细节，如细线、孤立点和噪声有较强的响应；
- ❑ 3. 二阶导数在灰度斜坡和灰度台阶过渡处会产生**双边缘响应**；
- ❑ 4. 二阶导数的**符号**可用于确定边缘的过渡是从亮到暗还是从暗到亮。

孤立点的检测


- 用二阶导——拉普拉斯
 - 直观上看，是一个孤立点的灰度将完全不同于其周围像素的灰度。

1	1	1
1	-8	1
1	1	1



线检测

- 可以用拉普拉斯模板，但二阶导数的双线必须做适当处理（用绝对值会使线宽加倍，可以仅保留拉普拉斯的正值）。



a	b
c	d


FIGURE 10.5

(a) Original image.
(b) Laplacian image; the magnified section shows the positive/negative double-line effect characteristic of the Laplacian.
(c) Absolute value of the Laplacian.
(d) Positive values of the Laplacian.

线检测


- 多方向（各向异性）的线检测
 - （第一行）原图和使用45度线检测算子的检测结果
 - （中间行）左上和右下局部位置放大图
 - 对一个线宽的45度左右线具有更强烈响应
 - （最下行）左上图中负值置零；保留大于阈值的线的结果

-1	-1	-1	2	-1	-1	-1	2	-1	-1	-1	2
2	2	2	-1	2	-1	-1	2	-1	-1	2	-1
-1	-1	-1	-1	-1	2	-1	2	-1	2	-1	-1
Horizontal			+45°			Vertical			-45°		




边缘模型

- 三种边缘模型：台阶、斜坡和屋顶




边缘模型

- ❑ 一阶导数的幅度可用于检测图像中是否存在边缘；二阶导数的符号可确定一个边缘像素位于暗的一侧还是亮的一侧；
- ❑ 二阶导数的零交叉点可用于定位粗边缘的中心。



边缘模型


- 有噪声边缘的一阶和二阶导数性质
 - 导数对噪声十分敏感；
 - 二阶导数对噪声更加敏感；
 - 使用导数之前的平滑处理是必须考虑的问题



实际的边缘

- 边缘检测的一般步骤
 - 对图像平滑处理；
 - 边缘点的检测（利用某种局部算子或者操作）；
 - 边缘定位。

实际图像边界



图像的边缘及其导数

边缘算子

1. 梯度算子


- 对于连续函数 $f(x,y)$, 它在 (x,y) 处的梯度

$$\nabla f(x,y) = \begin{bmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} \end{bmatrix}^T = [G_x \quad G_y]^T$$

- 梯度矢量的幅度 (常直接简称为梯度)

$$\|\nabla f\| = [G_x^2 + G_y^2]^{1/2}$$

- 梯度矢量的方向角 $\phi(x,y) = \arctan(G_y/G_x)$



-1	-1	-1	-1	0	1
0	0	0	-1	0	1
1	1	1	-1	0	1

Prewitt

$$\nabla f(x,y) = \begin{bmatrix} \frac{\partial f}{\partial x} & \frac{\partial f}{\partial y} \end{bmatrix}^T = [-2, 2]^T$$

- 对数字图像，用差分代替微分计算 G_x 和 G_y

- 梯度幅度可用下式简化

$$\|\nabla f\| = |G_x| + |G_y|$$

$$\|\nabla f\| = \max\{|G_x|, |G_y|\}$$

- 基本梯度算子

-1	-1
1	1

- 罗伯特交叉 (Roberts) 算子

$$G_y = f(x+n, y) - f(x, y+n)$$

$$G_x = f(x, y) - f(x+n, y+n)$$

-1	0	0	-1
0	1	1	0

Roberts

- 这里 n 为一小整数，称为跨距。常取 $n=1$ 。

3×3的梯度算子

- **Prewitt**算子实现较简单，但**Sobel**算子对噪声的抑制能力更好些，一般**Sobel**算子有较好的效果；
- 为降低计算量，梯度幅度也可以用绝对值来代替；

$$\nabla f \approx |g_x| + |g_y|$$

-1	-1	-1	-1	0	1
0	0	0	-1	0	1
1	1	1	-1	0	1

Prewitt

-1	-2	-1	-1	0	1
0	0	0	-2	0	2
1	2	1	-1	0	1

Sobel

0	1	1	-1	-1	0
-1	0	1	-1	0	1
-1	-1	0	0	1	1

Prewitt


0	1	2	-2	-1	0
-1	0	1	-1	0	1
-2	-1	0	0	1	2

Sobel

检测对角边缘的Prewitt和Sobel模板




(a)原图



(b) $G_x + 128$




(c) $|G_x|$




(d) $G_y + 128$




(e) $|G_y|$



(f)梯度的模



(g) $|G_x| + |G_y|$



(h) $\max\{|G_x|, |G_y|\}$

用Sobel算子的梯度图示例



a	b
c	d

FIGURE 10.16

(a) Original image of size 834×1114 pixels, with intensity values scaled to the range $[0, 1]$.

(b) $|g_x|$, the component of the gradient in the x -direction, obtained using the Sobel mask in Fig. 10.14(f) to filter the image.

(c) $|g_y|$, obtained using the mask in Fig. 10.14(g).

(d) The gradient image, $|g_x| + |g_y|$.

使用sobel模板的边缘图

梯度方向图

■ 边缘梯度方向图





FIGURE 10.17


Gradient angle image computed using Eq. (10.2-11). Areas of constant intensity in this image indicate that the direction of the gradient vector is the same at all the pixel locations in those regions.

去除细小边缘

- 5*5模板平滑后求梯度得到的结果;



- 采用45度模板得到的梯度图




0	1	2	-2	-1	0
-1	0	1	-1	0	1
-2	-1	0	0	1	2

Sobel

平滑与阈值处理相结合的梯度

- 用无平滑和有平滑处理获得的梯度图，进行最高值**33%**作为阈值，二值化后得到的最终边缘。



无、有平滑
的梯度图

二值化后的
最终边缘图，
注意瓦片边
缘的消失

2. 拉普拉斯算子的边缘检测

- 连续函数 $f(x,y)$ 在 (x,y) 点的拉普拉斯(Laplacian)算子定义为

$$\nabla^2 f(x,y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

- 对于数字图像,常用如下模板实现

	-1	
-1	4	-1
	-1	

(a)


-1	-1	-1
-1	8	-1
-1	-1	-1

(b)

-1		-1
	4	
-1		-1

(c)

拉普拉斯算子模板



(a)灰度图像

(b)拉普拉斯算子结果

(c)过零点检测

拉普拉斯算子模板检测边缘

- ❑ 拉普拉斯算子的**缺点**是：
 - （1）边缘元的方向信息被丢失；
 - （2）采用二阶差分，双倍加强了图像中的噪声。
- ❑ 拉普拉斯算子的**优点**是：
 - 各向同性，即旋转不变。

Marr-Hildreth边缘检测器（LOG）

- 需要考虑图像噪声和边缘本身特性；
- 理想的边缘检测器应该满足的特点：
 - 1. 应该是一个能计算图像中每一点处一阶或者二阶导数的数字近似的微分算子；
 - 2. 应该能被调整以便在任何期望的尺寸上起作用。
比如：大的算子用于检测模糊边缘，小的算子用于检测精细细节。
- Marr和Hildreth论证了满足这些条件的最令人满意的算子是滤波器 $\nabla^2 G$ （即**LOG**）

Marr-Hildreth边缘检测器

- 先对图像作高斯滤波，即与如下二维高斯函数卷积：

$$h(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

- 则卷积后图像的拉普拉斯图像为 $h(x, y) * f(x, y)$

- 而 $\nabla^2 [h(x, y) * f(x, y)] = \nabla^2 [h(x, y)] * f(x, y)$

$$\nabla^2 [h(x, y)] = \frac{\partial^2 h}{\partial x^2} + \frac{\partial^2 h}{\partial y^2}$$

$$= \frac{1}{2\pi\sigma^2} \left(\frac{x^2 + y^2 - 2\sigma^2}{\sigma^4} \right) \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

——高斯型的拉普拉斯算子(Laplacian of a Gaussian, LoG)




LoG (墨西哥草帽算子)

□ 令 $r^2 = x^2 + y^2$

- 由于只关心过零点, 且式中系数及其正负不影响结果, 可改用

$$\nabla^2 h = \left(1 - \frac{r^2}{2\sigma^2}\right) \exp\left(-\frac{r^2}{2\sigma^2}\right)$$

- 对于数字图像, 我们对该函数进行取样, 然后用叠加算子进行卷积
- 中央正值区的宽度与 σ 有关
 - 可取模板尺寸 $n \geq 6\sigma$ 的最小奇整数



0	0	-1	0	0
0	-1	-2	-1	0
-1	-2	16	-2	-1
0	-1	-2	-1	0
0	0	-1	0	0

❑ Marr-Hildreth边缘检测器的计算的两种方法



- (1) 先高斯滤波再用Laplacian算子
- (2) 直接用LoG算子,
- 无论是(1)还是(2), 都需要找零交叉;
- 将LoG算子分解成行列分离操作, 从而提高速度

❑ Marr-Hildreth边缘检测器特点:

- 有较强的噪声抑制能力
- 检测到的边沿的宽度为一个像素
- 检测到的边缘连成闭合曲线
- 利用LoG算子还可直接得到目标区域的二值图
- 主要缺点是计算量太大

- 找过零交叉时需要测试：(1)当前像素3*3邻域内，上下、左右、对角等四个方向上存在两侧的符号不同；(2)而且他们数值差的绝对值必须超过一个阈值t。

t=0的过零点



a b
c d

n=25的LOG算子

FIGURE 10.22


(a) Original image of size 834×1114 pixels, with intensity values scaled to the range $[0, 1]$. (b) Results of Steps 1 and 2 of the Marr-Hildreth algorithm using $\sigma = 4$ and $n = 25$. (c) Zero crossings of (b) using a threshold of 0 (note the closed-loop edges). (d) Zero crossings found using a threshold equal to 4% of the maximum value of the image in (b). Note the thin edges.

t=4%*Max的过零点



(a) 原图


(b) Sobel梯度图



(c) 高斯函数

-1	-1	-1
-1	8	-1
-1	-1	-1

(d) 拉普拉斯算子




(e) 运用LoG后的图

(f) 图(e)的二值化

(g) 过零点形成边缘


用Marr算子得到的边缘




(a) 原图




(b) $\sigma = 3$




(c) $\sigma = 5$



(d) $\sigma = 6$



(e) $\sigma = 7$



(f) $\sigma = 9$

不同 σ 的Marr检测器得到的边缘

LOG和DOG的关系


- 可以用高斯差分DOG来近似LOG:

$$DOG(x, y) = \frac{1}{2\pi\sigma_1^2} e^{-\frac{x^2+y^2}{2\sigma_1^2}} - \frac{1}{2\pi\sigma_2^2} e^{-\frac{x^2+y^2}{2\sigma_2^2}}, \text{ 其中 } \sigma_1 > \sigma_2$$

- Mar建议, 使用1.6:1比例的DOG可对LOG函数提供一个很接近的工程近似, 此时LOG的方差选为

$$\sigma^2 = \frac{\sigma_1^2 \sigma_2^2}{\sigma_1^2 - \sigma_2^2} \ln \left[\frac{\sigma_1^2}{\sigma_2^2} \right]$$

LOG **DOG**



a b

FIGURE 10.23
(a) Negatives of the LoG (solid) and DoG (dotted) profiles using a standard deviation ratio of 1.75:1.
(b) Profiles obtained using a ratio of 1.6:1.

坎尼（Canny）边缘检测算子

- 提出评价边缘检测性能的三个指标：
 - （1）低错误率，即将非边缘点判为边缘点的概率要低，将边缘点判为非边缘点的概率也要低；
 - （2）好的定位性能，即检测出的边缘点要尽可能在实际边缘的中心；
 - （3）单一的边缘响应，即单个边缘产生多个边缘响应的概率要低，且虚假边缘响应能得到最大的抑制。
- 据上述设计的边缘检测算子称为坎尼算子
- 实际应用中可以选取高斯函数的一阶导数作为阶跃形边缘的次优检测算子——坎尼算子的近似

- 设二维高斯函数为

$$h(x, y) = \frac{1}{2\pi\sigma^2} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

- 根据卷积公式

$$\nabla[f(x, y) * h(x, y)] = f(x, y) * \nabla h(x, y)$$

- 这里

$$\nabla h(x, y) = \begin{bmatrix} \partial h / \partial x \\ \partial h / \partial y \end{bmatrix} = \begin{bmatrix} -\frac{x}{2\pi\sigma^4} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \\ -\frac{y}{2\pi\sigma^4} \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right) \end{bmatrix}$$


- 从而可计算梯度的幅度(边缘强弱)和方向(垂直于边缘)

- 用坎尼算子检测边缘时，若像素满足以下三个条件，则认为图像边缘点：
 - （1）该点的边缘强度大于沿该点梯度方向的两个相邻像素点的边缘强度；
 - （2）与该点梯度方向上（近似）相邻两点的方向差小于 45° ；
 - （3）以该点为中心的 3×3 邻域中的边缘强度极大值大于某个阈值。

- 其中，条件（1）（2）确定单像素边缘点，采用非极大值抑制NMS。
 - （3）消除虚假边缘

Canny边缘点及其法线方向的非极大值抑制

1. 根据当前梯度方向将边缘归于四个方向之一；
2. 若当前梯度值至少小于沿边缘法方向的两个邻居之一，则抑制该点，作为非边缘点；否则作为边缘候选点；
3. 对边缘候选点进行双阈值处理和连接。



Canny边缘检测算法的步骤

- ❑ (1) 用一个高斯滤波器平滑输入图像；
- ❑ (2) 计算梯度幅值图像和角度图像；
- ❑ (3) 对梯度幅值图像应用（局部）非极大值抑制；
- ❑ (4) 双阈值处理和连接分析来检测并连接边缘。
 - 双阈值中，高低阈值比例建议为2:1或者3:1。
 - 后面可进一步采用形态学细化操作，细化边缘为1个像素



a b
c d

FIGURE 10.25


(a) Original image of size 834×1114 pixels, with intensity values scaled to the range $[0, 1]$.

(b) Thresholded gradient of smoothed image.

(c) Image obtained using the Marr-Hildreth algorithm.

(d) Image obtained using the Canny algorithm. Note the significant improvement of the Canny image compared to the other two.

Canny检测结果抑制了更多的无关特性，在连续性、细度和笔直度方面都不错。此例中， $Tl=0.04$ ， $Th=0.10$ ，高斯模板尺寸 $n=25$ 。



a	b
c	d

FIGURE 10.26

(a) Original head CT image of size 512×512 pixels, with intensity values scaled to the range $[0, 1]$.

(b) Thresholded gradient of smoothed image.

(c) Image obtained using the Marr-Hildreth algorithm.

(d) Image obtained using the Canny algorithm.


(Original image courtesy of Dr. David R. Pickens, Vanderbilt University.)

边缘的连接和边界检测

- 在边缘检测后紧跟连接算法，经边缘像素组合成为有意义的边缘或者区域边界；
- 有三种代表性的方法
 - 1. 局部连接：需要局部邻域中边缘点的知识；
 - 2. 分段拟合：区域边界上的点已知；
 - 3. 全局方法：只需要已知所需要的边缘的描述方程。

边缘的局部连接

- 边缘元能够相互连接的基础是
 - 相邻并具有一定的相似性
- 边缘元的特征
 - 对梯度算子得到的边缘元:
 - 梯度幅度信息
 - 梯度方向信息
 - 如，像素 (s,t) 在像素 (x,y) 的邻域内，其梯度的幅度和方向满足：
$$\left| |\nabla f(x,y)| - |\nabla f(s,t)| \right| \leq T \quad \text{且} \quad |\nabla f(x,y)| \geq T_0, \quad |\nabla f(s,t)| \geq T_0$$
$$\left| \phi(x,y) - \phi(s,t) \right| \leq A$$
 - **T**是幅度阈值，**A**是角度阈值




在方向边缘的连接过程中填充了<25像素宽的间断缝隙

a	b	c
d	e	f

FIGURE 10.27 (a) A 534×566 image of the rear of a vehicle. (b) Gradient magnitude image. (c) Horizontally connected edge pixels. (d) Vertically connected edge pixels. (e) The logical OR of the two preceding images. (f) Final result obtained using morphological thinning. (Original image courtesy of Perceptics Corporation.)

分段拟合边缘

■ 原理




a	b
c	d

FIGURE 10.28
Illustration of the
iterative
polygonal fit
algorithm.

■ 寻找多边形拟合曲线的算法

1. 令**P**为一个已排序序列，指定两个起始点**A**和**B**；
2. 指定一个阈值**T**，以及两个空堆栈“开”和“闭”；
3. 如果**P**中的点对应一条闭合曲线，则把**A**放到“开”中，**B**放到“开”和“闭”中，如果对应于开放曲线，则**A**放“开”，**B**放“闭”；
4. 计算从“闭”中最后一个顶点到“开”中最后一个顶点的直线参数；
5. 计算步骤4所得的直线至**P**中所有点的距离，把序列放到步骤4所得的两个顶点之间。选择具有最大距离**D**的点**V**；
6. 如果**D>T**，则把**V**作为一个新顶点放在“开”堆栈的末尾，转到4；
7. 否则，从“开”中移除最后一个顶点，并把它作为“闭”的最后一个顶点插入；
8. 如果“开”非空，转到步骤4；
9. 否则，退出。“闭”中的顶点即使拟合**P**中的点的多边形的顶点。

寻找多边形拟合曲线的算法



CLOSED	OPEN	Curve segment processed	Vertex generated
<i>B</i>	<i>B, A</i>	—	<i>A, B</i>
<i>B</i>	<i>B, A</i>	(<i>BA</i>)	<i>C</i>
<i>B</i>	<i>B, A, C</i>	(<i>BC</i>)	—
<i>B, C</i>	<i>B, A</i>	(<i>CA</i>)	—
<i>B, C, A</i>	<i>B</i>	(<i>AB</i>)	<i>D</i>
<i>B, C, A</i>	<i>B, D</i>	(<i>AD</i>)	—
<i>B, C, A, D</i>	<i>B</i>	(<i>DB</i>)	—
<i>B, C, A, D, B</i>	Empty	—	—

例（优点：实现简单，结果可接受）




FIGURE 10.30 (a) A 550×566 X-ray image of a human tooth. (b) Gradient image. (c) Result of majority filtering. (d) Result of morphological shrinking. (e) Result of morphological cleaning. (f) Skeleton. (g) Spur reduction. (h)–(j) Polygonal fit using thresholds of approximately 0.5%, 1%, and 2% of image width ($T = 3, 6, \text{ and } 12$). (k) Boundary in (j) smoothed with a 1-D averaging filter of size 1×31 (approximately 5% of image width). (l) Boundary in (h) smoothed with the same filter.

边缘连接和边界检测的全局处理

- 当工作在无结构的环境中，所拥有的只是一幅边缘图像，没有关于感兴趣目标可能在哪里的知识，所有像素都是连接的候选点；
- 必须基于预先定义的全局性质接受或者删除某些点；
- 霍夫变换——检测像素集是否位于指定形状曲线上的方法。

全局处理

■ 霍夫（Hough）变换——已知形状的曲线检测

□ 1.直线检测

- 直线方程: $y = kx + b$

$$r = x \cos \theta + y \sin \theta$$


- 对于一条直线， θ 和 r 是确定的

- 直线上的一个点 (x_0, y_0)

$$r = x_0 \cos \theta + y_0 \sin \theta$$

- $\theta \sim r$ 为一条正弦曲线

- 用 $\theta \sim r$ 构成坐标系称为参数空间




直线的表示


■ 可用频度是否超过阈值来检测直线

■ 具体操作

- ❑ θ 的取值为 $[-90^\circ, 90^\circ]$
- ❑ 1.若图像尺寸为 $N \times N$ ，则 r 的取值为 $[-\sqrt{2}N, \sqrt{2}N]$
- ❑ 2.若将 θ 的取值量化为 $0^\circ, \pm 15^\circ, \pm 30^\circ, \pm 45^\circ, \pm 60^\circ, \pm 75^\circ, +90^\circ$ ，则共有12个值
- ❑ 3.若将 r 的取值量化为50个等分
- ❑ 则共有 12×50 个单元，可统计每个单元中正弦曲线出现的频度；若频度超过某阈值，则认为有对应该 (θ_0, r_0) 值的直线。
- ❑ 检验选中单元像素间的关系
(主要是连续性)

共线的点对应参数空间中的正弦曲线







a
b


FIGURE 10.33

(a) Image of size 101×101 pixels, containing five points.
(b) Corresponding parameter space. (The points in (a) were enlarged to make them easier to see.)







(a) 一幅红外航空图像



(b) 利用Sobel算子检测到的边缘



(c) 霍夫变换结果



(d) 检测到的三条直线

霍夫变换的应用实例

- $r\theta$ 平面中的细分数量决定了这些点的共线性的精确度。可以证明，该方法的计算次数与 xy 平面中非背景点的数量 n 呈线性关系；
 - 如果 r 和 θ 量化过粗
 - 则找到的 r_0 、 θ_0 值太粗糙，不能精确定位直线
 - 若 r 和 θ 量化过细
 - 则计算量大，且落入单元格中的点数过于分散，不能有效地进行检测
 - 若图像中直线边缘的大致方向已有估计
 - 可在其相应方向的一定范围内把 θ 精细量化，其它 θ 则采用粗量化
- 也可用其它直线方程形式

- 霍夫变换也适用于形如 $g(x, y) = 0$ 的任何函数。
- 例如：圆的检测
 - 圆的一般方程 $(x - a)^2 + (y - b)^2 = r^2$
 - 有 **a, b, r** 三个参数, 对于图像上的一个边缘点 (x_0, y_0)
 $(x_0 - a)^2 + (y_0 - b)^2 = r^2$
 - 变 **a, b** 可得 **r**, 在三维参数空间上进行参数投票累加。

使用霍夫变换连接边缘




FIGURE 10.34 (a) A 502×564 aerial image of an airport. (b) Edge image obtained using Canny's algorithm. (c) Hough parameter space (the boxes highlight the points associated with long vertical lines). (d) Lines in the image plane corresponding to the points highlighted by the boxes. (e) Lines superimposed on the original image.

■ Hough变换的缺点

- 曲线参数空间的量化精度不易确定，需要结合实际多次调整
 - 由于没有图像的先验知识，这种调整是不容易的
- 不合理的量化可能产生如下问题：
 - 不能检测特殊曲线
 - 难于找到局部最大值
 - 低精度
 - 较大的存储空间
 - 较低的计算速度

■ 改进：随机Hough变换

8.3 基于阈值处理的分割

- 阈值处理直观，实现简单速度快，在图像分割应用中处于核心地位
- 利用同一区域内像素相似性进行图像分割的技术
 - 最简单的分割方法——按灰度值二值化

$$g(x, y) = \begin{cases} L_A & f(x, y) \leq T \\ L_B & f(x, y) > T \end{cases}$$


- 一般背景用0，目标用1，也可用其它任何灰度级
- 阈值的一般形式

$$T = T[x, y, f(x, y), p(x, y)]$$

- $p(x, y)$ 是图像的邻域局部特征

阈值的分类


- 阈值分割可分为三种 $T = T[x, y, f(x, y), p(x, y)]$
 - **全局阈值**:如果阈值只与图像灰度有关, 且整幅图像采用统一阈值
 - **局部阈值**:如果阈值与局部特性有关
 - **动态阈值**:如果阈值不仅与局部特性有关, 而且与坐标位置也有关




(a)单阈值分割

(b)多阈值分割

全局阈值分割




(a)骨髓细胞图



(b)阈值 $T=165$



(c)阈值 $T=237$



(d)双阈值

全局阈值分割示例 $T_1=165, T_2=237$

8.3 阈值分割的一些观察

- 直方图模式的谷的宽度和深度直接关系到灰度阈值法分割的成功与否。
- 影响波谷特性的关键因素：
 - 波峰间的间隔；
 - 图像中的噪声内容；
 - 物体和背景的相对尺寸
 - 光源的均匀性；
 - 图像反射特性的均匀性。

图像阈值处理中噪声的影响




FIGURE 10.36 (a) Noiseless 8-bit image. (b) Image with additive Gaussian noise of mean 0 and standard deviation of 10 intensity levels. (c) Image with additive Gaussian noise of mean 0 and standard deviation of 50 intensity levels. (d)–(f) Corresponding histograms.

光照和反射的影响





FIGURE 10.37 (a) Noisy image. (b) Intensity ramp in the range [0.2, 0.6]. (c) Product of (a) and (b). (d)–(f) Corresponding histograms.

■ 依赖像素的阈值选取


■ 1. 基本全局阈值

■ 简单的确定阈值的方法:


- 灰度中间（如**128**）
- 灰度平均值
- 灰度最大值和最小值的平均(右图)
-



(a)工件图



(b)图(a)的直方图



(c)二值化图

采用全局阈值的简单二值化

一种自动确定全局阈值的迭代方法


- 1) 选取一个T的初始值
- 2) 用T分割图像。这会将像素分成 G_1 和 G_2 二组， G_1 中的像素灰度值大于T， G_2 中的像素灰度值小于或等于T
- 3) 对区域 G_1 和 G_2 中的所有像素计算平均灰度值 μ_1 和 μ_2
- 4) 计算新的门限值 $T = \frac{1}{2}(\mu_1 + \mu_2)$
- 5) 重复步骤2)到4)，直到逐次迭代所得的T值之差小于某一预定值

相当于k=2时的K-Mean聚类算法

■ 用迭代法确定
门限进行二值
化

- (a) 指纹图像
- (b) 直方图
- (d) 二值化图

三次迭代, 得 $T=125.4$



使用Otsu方法的全局最优阈值处理

- ❑ 假设图像中只有目标和背景，设置一个门限 T
 - 使分割后目标内部和背景内部总方差（称为类内方差）较小
 - 而目标与背景的灰度平均值之差又达较大（用类间方差表示）
- ❑ 对两类：
 - 像素频度分别为 P_1 和 P_2 ， $P_1+P_2=1$
 - 平均灰度值分别为 μ_1 和 μ_2
 - 方差分别为 σ_1^2 和 σ_2^2
- ❑ 整幅图的平均灰度为 μ_t ，则类内方差为

$$\sigma_w^2 = P_1\sigma_1^2 + P_2\sigma_2^2$$

□ 类间方差为 $\sigma_B^2 = P_1(\mu_1 - \mu_t)^2 + P_2(\mu_2 - \mu_t)^2$

■ 因 $\mu_t = P_1\mu_1 + P_2\mu_2$ 代入

■ 有 $\sigma_B^2 = P_1P_2(\mu_1 - \mu_2)^2 = \frac{P_1}{(1-P_1)} \cdot (\mu_t - \mu_1)^2$

■ 取使类间方差最大(即 $\frac{\sigma_B^2}{\sigma_w^2}$ 最大)的 $\mathbf{T}$ 作为最佳阈值

■ 为计算方便, 可用使 σ_B^2 为最大来近似代替 $\frac{\sigma_B^2}{\sigma_w^2}$ 最大


□ 先计算 $P_1 = \sum_{i=0}^T p(i)$ $\mu_1 = \sum_{i=0}^T i \cdot p(i) / P_1$, 再计算 σ_B^2

□ 使用穷举法, 找到使 σ_B^2 最大的 $\mathbf{T}$ (最大值不唯一, 可取平均)

□ 最佳阈值处的归一化度量 $\eta(k^*) = \sigma_B^2(k^*) / \sigma_G^2$ 作为类别可分性的定量估计;

□ 已有一些迭代算法, 用于快速找到使 σ_B^2 最大的阈值 $\mathbf{T}$

基本全局阈值处理法：
T=169




a	b
c	d

FIGURE 10.39

(a) Original image.
(b) Histogram (high peaks were clipped to highlight details in the lower values).
(c) Segmentation result using the basic global algorithm from Section 10.3.2.
(d) Result obtained using Otsu's method. (Original image courtesy of Professor Daniel A. Hammer, the University of Pennsylvania.)

Otsu法: T=181,
可分性度量: $\eta = 0.467$

用图像平滑改善全局阈值处理




平滑带来的
巨大改进!

a	b	c
d	e	f

FIGURE 10.40 (a) Noisy image from Fig. 10.36 and (b) its histogram. (c) Result obtained using Otsu's method. (d) Noisy image smoothed using a 5×5 averaging mask and (e) its histogram. (f) Result of thresholding using Otsu's method.

前景相对背景大小对分割的影响



前景区域太小，
对直方图的贡献
与由噪声引起的
灰度扩散相比，
显得无足轻重。

FIGURE 10.41 (a) Noisy image and (b) its histogram. (c) Result obtained using Otsu's method. (d) Noisy image smoothed using a 5×5 averaging mask and (e) its histogram. (f) Result of thresholding using Otsu's method. Thresholding failed in both cases.

利用边缘改进全局阈值处理

- ❑ **观察：** 如果直方图的两个波峰高、窄、对称，波谷深，则容易找到好的全局阈值。
- ❑ **思想：**
 - 1. 仅用位于或者接近边缘的像素，则得到的直方图将有几个高度近似相同的波峰。
 - 2. 像素位于物体和背景上的概率近似相等，改善了直方图模式的对称性；
 - 3. 用满足基于梯度和拉普拉斯算子的简单度量的像素有加深直方图波峰间的波谷的倾向。
- ❑ **算法：**
 - 1. 计算原图的边缘图；
 - 2. 指定阈值 T ，并对边缘图进行二值处理，获取强边缘点，作为模板图像；
 - 3. 仅用模板图像对应的**原图像素**计算直方图；
 - 4. 利用获得的边缘像素直方图，做全局分割（如**Otsu**方法等）。

利用梯度为主的边缘信息改善分割





FIGURE 10.39 (a) Noisy image from Fig. 10.38(a) and (b) its histogram. (c) Mask image formed as the gradient magnitude image thresholded at the 99.7 percentile. (d) Image formed as the product of (a) and (c). (e) Histogram of the nonzero pixels in the image in (d). (f) Result of segmenting image (a) with the Otsu threshold based on the histogram in (e). The threshold was 134, which is approximately midway between the peaks in this histogram.



利用拉普拉斯为基础的边缘信息改进全局阈值处理

希望分割得到
亮点区域

Otsu方法
 $T=42$ ，可分
度0.636



拉普拉斯边缘图
 $T1=115(99.5\%)$ ，
Otsu方法 $T=115$ ，
可分度0.762



拉普拉斯边缘
图 $T1=55(5\%)$ ，
再施加Otsu
方法的结果



a b c
d e f

FIGURE 10.43 (a) Image of yeast cells. (b) Histogram of (a). (c) Segmentation of (a) with Otsu's method using the histogram in (b). (d) Thresholded absolute Laplacian. (e) Histogram of the nonzero pixels in the product of (a) and (d). (f) Original image thresholded using Otsu's method based on the histogram in (e). (Original image courtesy of Professor Susan L. Forsburg, University of Southern California.)

多阈值处理（多类的Otsu方法）

- 在k个类 $C_1, C_2, \dots, C_k$ 的情况下，类间方差可归纳为

$$\sigma_B^2 = \sum_{k=1}^K P_k (m_k - m_G)^2$$

- 其中 $P_k = \sum_{i \in C_k} p_i$, $m_k = \frac{1}{P_k} \sum_{i \in C_k} ip_i$
- K类由K-1个阈值来分离，即使下式成立：

$$\sigma_B^2(k_1^*, k_2^*, \dots, k_{K-1}^*) = \max_{0 < k_1 < k_2 < \dots < L-1} \sigma_B^2(k_1, k_2, \dots, k_{K-1})$$

同样采用全局遍历方法可以求解（对多个 k 设置嵌套for 循环）

可分性度量： $\eta(k_1^*, k_2^*) = \frac{\sigma_B^2(k_1^*, k_2^*)}{\sigma_G^2}$

三个类的分割例子




FIGURE 10.45 (a) Image of iceberg. (b) Histogram. (c) Image segmented into three regions using dual Otsu thresholds. (Original image courtesy of NOAA.)

可变阈值处理

- 局部阈值法

- 问题:光照不均匀或透射不均匀时, 整幅图像的分割没有合适的单一门限


- 1.阴影校正:

- 先采集一幅没有目标的背景图像, 与有目标的图相减, 从而消除光照不均匀现象

- 2.局部阈值法: (无法得到背景图像)

- 把图像分块, 对每块选取一局部门限进行分割
 - 如果某图像块内有目标和背景, 则直方图呈双峰, 据此可确定局部门限
 - 如果图像块内只有目标或只有背景, 则直方图不呈双峰, 找不出合适的局部门限值, 但可根据邻近的双峰的块得到局部门限, 通过内插给该图像块规定一门限, 从而进行分割

通过图像分块的可变阈值分割



基于局部图像特性的可变阈值处理

- 为每个像素点计算一个阈值（自适应）：
 - 在每个像素点的一个邻域内的像素的**标准差**和**均值**，它们是局部对比度和平均灰度的描述子。
 - 使用以（**x,y**）的参数为基础的属性：


- $$g(x,y) = \begin{cases} 1, & Q=True \\ 0, & Q=False \end{cases} \quad \text{其中:}$$

$$Q(\sigma_{xy}, m_{xy}) = \begin{cases} True, & f(x,y) > a\sigma_{xy} \text{ AND } f(x,y) > bm_{xy} \text{ (or } bm_G) \\ False, & \text{others} \end{cases}$$

排除边缘像素，因此能
把物体边缘更容易分开。
通常边缘的方差较大，
该条件不易满足

背景近似恒定时，获得
前景像素

基于局部图像特性的可变阈值处理



a b
c d

FIGURE 10.43

(a) Image from Fig. 10.40.

(b) Image segmented using the dual thresholding approach given by Eq. (10-76).

(c) Image of local standard deviations.

(d) Result obtained using local thresholding.

3*3邻域内计算
均值和方差

$a=30$, $b=1.5$


使用移动平均的可变阈值处理

- 对文档处理特别适合
- 对图像中的每个像素点计算移动平均：

$$m_{xy}(k+1) = \frac{1}{n} \sum_{i=k+2-n}^{k+1} z_i = m_{xy}(k) + \frac{1}{n} (z_{k+1} - z_{k-n})$$

- 用如下式子计算分割

$$g(x, y) = \begin{cases} 1, & f(x, y) > T_{xy} \\ 0, & f(x, y) \leq T_{xy} \end{cases}, \text{ where } T_{xy} = b m_{xy}$$



- 适用于感兴趣的物体与图像尺寸相比较小（较细） 场合。相当于滑动分块分割。




FIGURE 10.49 (a) Text image corrupted by spot shading. (b) Result of global thresholding using Otsu's method. (c) Result of local thresholding using moving averages.

窗口宽度 n 取平均笔画宽度的5倍，此例中 $n=20$, $b=0.5$ 。





FIGURE 10.50 (a) Text image corrupted by sinusoidal shading. (b) Result of global thresholding using Otsu's method. (c) Result of local thresholding using moving averages.


多变量阈值处理（彩色图像）

- 阈值分割模型（矢量阈值分割）

$$g(x,y) = \begin{cases} 1, & D(\mathbf{z}, \mathbf{a}) < T \\ 0, & \text{Others} \end{cases}$$



- 其中： $D(\mathbf{z}, \mathbf{a}) = \|\mathbf{z} - \mathbf{a}\| = \left[(\mathbf{z} - \mathbf{a})^T (\mathbf{z} - \mathbf{a}) \right]^{1/2}$ （欧氏距离）
- 或者： $D(\mathbf{z}, \mathbf{a}) = \|\mathbf{z} - \mathbf{a}\| = \left[(\mathbf{z} - \mathbf{a})^T \mathbf{C}^{-1} (\mathbf{z} - \mathbf{a}) \right]^{1/2}$ （马氏距离）




8.4 基于区域的分割

区域生长

- 基本思想:
 - 将具有相似性质的像素聚集到同一区域
- 方法:
 - 先对每个需要分割的区域找一个种子像素作为生长的起点
 - 然后将种子像素周围与种子像素有相同或相似性质的像素，加入到种子像素所在的区域中（注意生长过程中要保持区域内的连通性）
 - 再将这些新加入的像素做为新的种子，继续进行上面的过程，直到不再有像素加入区域

- 在实际应用区域生长法时需要解决三个问题：
 - 选定一组能正确代表所需区域的种子像素；
 - 确定生长过程中将相邻像素加入进来的准则；
 - 设定过程停止的条件。




这里T是与选定种子像素的差值的阈值

腐蚀后的
种子点

双阈值分割法
作用于差值图
像结果

T1= 68;

T2=126



阈值为254
(99.5%)


原图与种子
区域的差值
(不相似性)
直方图

区域生长
最终结果

T=68

a	b	c
d	e	f
g	h	i

FIGURE 10.51 (a) X-ray image of a defective weld. (b) Histogram. (c) Initial seed image. (d) Final seed image (the points were enlarged for clarity). (e) Absolute value of the difference between (a) and (c). (f) Histogram of (e). (g) Difference image thresholded using dual thresholds. (h) Difference image thresholded with the smallest of the dual thresholds. (i) Segmentation result obtained by region growing. (Original image courtesy of X-TEK Systems, Ltd.)




例,准则：（1）与种子像素间的灰度差绝对值小于65，这个数值是通过分析直方图获得（双阈值otsu分割法）；（2）加入像素须与已生长区域八连通。如果某个像素与多个生长区域连通，则将这些区域合并。


区域分裂与聚合

- 将一幅图像细分为一组任意的不相交区域，然后聚合或分裂这些区域，并使其满足分割条件。
 - 通常将图像按4象限方式分裂成4个区域，可用4叉树形式表示；
 - 对每个区域，检查内部相似性
 - 如果区域内部像素性质不一致，则对该区域进一步分裂
 - 如果相邻区域有相似的性质，则将它们合并
 - 被合并的区域可能有不同形状和大小

■ 分裂合并法 与 四叉树



(a) 被分割的图像



(b) 对应的四叉树


区域的分裂合并

- 采用区域分裂合并方法的例子

- 相似性准则:


- 区域内至少有**80%**像素灰度值集中在其均值附近

$$|x_{ij} - m_i| \leq 2\sigma_i$$



区域的分裂合并示意图

利用分裂聚合法对星座环分割



相似性准则:

$$Q = \begin{cases} \text{True}, & \sigma > a \quad \text{and} \quad 0 < m < b \\ \text{False}, & \text{Others} \end{cases}$$

a	b
c	d

FIGURE 10.53

(a) Image of the Cygnus Loop supernova, taken in the X-ray band by NASA's Hubble Telescope. (b)–(d) Results of limiting the smallest allowed quadregion to sizes of 32×32 , 16×16 , and 8×8 pixels, respectively. (Original image courtesy of NASA.)

使用k均值聚类的区域分割

- 基本思想：将向量观测集合 $\mathbf{Q}$ 划分为规定数量 k 的聚类。在聚类过程中，每个观测值都被分配给具有最近均值的类别。

- 令 $\mathbf{z} = \begin{bmatrix} z_1 \\ z_2 \\ \vdots \\ z_n \end{bmatrix}$ ，k-means 方法的优化目标为

$$\arg \min_C \left(\sum_{i=1}^k \sum_{\mathbf{z} \in C_i} \|\mathbf{z} - \mathbf{m}_i\|^2 \right)$$

K-means具体算法

- (1) 初始化算法：规定一组初始均值 $\mathbf{m}_i(1), i = 1, 2, \dots, k$.
- (2) 将样本分配给聚类：将每个样本分配的均值最接近的类别集合，即：

$$\mathbf{z}_q \rightarrow C_i \text{ if } \|\mathbf{z}_q - \mathbf{m}_i\|^2 < \|\mathbf{z}_q - \mathbf{m}_j\|^2 \quad j = 1, 2, \dots, k (j \neq i); \quad q = 1, 2, \dots, Q$$

- (3) 更新聚类中心（均值）：
$$\mathbf{m}_i = \frac{1}{|C_i|} \sum_{\mathbf{z} \in C_i} \mathbf{z} \quad i = 1, 2, \dots, k$$
- (4) 完备性验证：计算当前步骤和前几步平均向量之间的差的欧氏范数。若该残差小于预设阈值，则停止；否则返回步骤2.

K-means 例子

a b

FIGURE 10.49


(a) Image of size 688×688 pixels.

(b) Image segmented using the k -means algorithm with $k = 3$.



使用超像素的区域分割

- 主要思想是通过将像素组合到比各个像素更有感知意义的原始区域来取代标准像素网格。
- 目的是减少计算开销，并通过减少不相关的细节来提高分割算法的性能。



a b c

FIGURE 10.50 (a) Image of size 600×480 (480,000) pixels. (b) Image composed of 4,000 superpixels (the boundaries between superpixels (in white) are superimposed on the superpixel image for reference—the boundaries are not part of the data). (c) Superpixel image. (Original image courtesy of the U.S. National Park Services.).

超像素数目的限制



FIGURE 10.51 Top row: Results of using 1,000, 500, and 250 superpixels in the representation of Fig. 10.50(a). As before, the boundaries between superpixels are superimposed on the images for reference. Bottom row: Superpixel images.

SLIC超像素算法

- 通常使用包含三个颜色分量和两个空间坐标的五维向量;

$$\mathbf{z} = \begin{bmatrix} r \\ g \\ b \\ x \\ y \end{bmatrix}$$

- 算法步骤见右侧。
- 与k-means相比:
 - (1) 距离D不规定为欧氏范数;
 - (2) 距离只针对 $2s \times 2s$ 区域范围内计算, 减少计算时间

1. **Initialize the algorithm:** Compute the initial superpixel cluster centers,

$$\mathbf{m}_i = [r_i \ g_i \ b_i \ x_i \ y_i]^T, \ i = 1, 2, \dots, n_{sp}$$

by sampling the image at regular grid steps, s . Move the cluster centers to the lowest gradient position in a 3×3 neighborhood. For each pixel location, p , in the image, set a label $L(p) = -1$ and a distance $d(p) = \infty$.

2. **Assign samples to cluster centers:** For each cluster center $\mathbf{m}_i$, $i = 1, 2, \dots, n_{sp}$, compute the distance, $D_i(p)$ between $\mathbf{m}_i$ and *each* pixel p in a $2s \times 2s$ neighborhood about $\mathbf{m}_i$. Then, for each p and $i = 1, 2, \dots, n_{sp}$, if $D_i < d(p)$, let $d(p) = D_i$ and $L(p) = i$.
3. **Update the cluster centers:** Let C_i denote the set of pixels in the image with label $L(p) = i$. Update $\mathbf{m}_i$:

$$\mathbf{m}_i = \frac{1}{|C_i|} \sum_{\mathbf{z} \in C_i} \mathbf{z} \quad i = 1, 2, \dots, n_{sp}$$

where $|C_i|$ is the number of pixels in set C_i , and the $\mathbf{z}$'s are given by Eq. (10-86).

4. **Test for convergence:** Compute the Euclidean norms of the differences between the mean vectors in the current and previous steps. Compute the residual error, E , as the sum of the n_{sp} norms. If $E < T$, where T a specified nonnegative threshold, go to Step 5. Else, go back to Step 2.
5. **Post-process the superpixel regions:** Replace all the superpixels in each region, C_i , by their average value, $\mathbf{m}_i$.

SLIC中的距离测度

- 颜色和空间坐标的尺度不同，且不相关，考虑分开处理，如：

$$d_c = [(r_j - r_i)^2 + (g_j - g_i)^2 + (b_j - b_i)^2]^{1/2} \quad d_s = [(x_j - x_i)^2 + (y_j - y_i)^2]^{1/2}$$

$$D = \left[\left(\frac{d_c}{d_{cm}} \right)^2 + \left(\frac{d_s}{d_{sm}} \right)^2 \right]^{1/2}$$

- 也可以令 $d_{cm} = c$ ，则有

$$D = \left[\left(\frac{d_c}{c} \right)^2 + \left(\frac{d_s}{s} \right)^2 \right]^{1/2} \quad \text{或者} \quad D = \left[d_c^2 + \left(\frac{d_s}{s} \right)^2 c^2 \right]^{1/2}$$

常数 c 用来加权颜色相似性和空间接近性之间的相对重要性。

使用超像素分割图像示例




FIGURE 10.52 (a) Image of size 533×566 (301,678) pixels. (b) Image segmented using the k -means algorithm. (c) 100-element superpixel image showing boundaries for reference. (d) Same image without boundaries. (e) Superpixel image (d) segmented using the k -means algorithm. (Original image courtesy of NOAA.)

使用图割分割区域

■ 原理


- 将图像像素表示为图的各个节点，求图到节点组的最优分割；

■ 最优准则

- 某个组内的成员的值较高，不同组中的成员的值较低

■ 特点

- 效果较优，计算复杂性较高




数学模型描述

- 图 G 示由节点集合 V 和连接这些顶点的边的结合 E 组成的数学结构：


$$G = (V, E)$$

- V 是一个集合， $E \subseteq V \times V$ 是 V 中有序元素对的集合。
- 有向图与无向图。在分割中，我们感兴趣的主要是无向图。
- 边由矩阵 W 表征，矩阵元素 $w(i, j) = w(j, i)$ 是连接节点 i 和 j 相关联的权重。
- W 是对称矩阵，权重与节点对之间的相似度成正比。边与权相关联的图称为加权图



图像分割问题


- 图的节点是像素（或者超像素）。通过将图 V 划分为多个不相交的子集。
- 关键问题：
 - 如何关联图和图像？
 - 边可以仅考虑4连通像素。
 - 边的权重通常由空间关系和灰度测度（如纹理和颜色）形成。
 - 如何切割图？
 - 图割方法



$$w(i, j) = 1 / (|I(n_i) - I(n_j)| + c)$$

图的另一种通用表示

- 增加了两个额外的节点：
 - ❑ 源终端节点与汇聚终端节点
 - ❑ 与之相连的边称为t链
 - ❑ 作用是将每个像素与是一个背景像素前景像素的概率关联起来，t链的权重就是概率。




最小图割

■ 最大流最小割定理：

- 在流网络中，从源终端节点传递到汇聚终端节点的最大流量等于最小割。
- 最小割定义为边的最小权重集合，若删除它则会断开汇聚终端节点与源终端节点，其为

$$cut(A, B) = \sum_{u \in A, v \in B} w(u, v)$$

- ## ■ 直接应用该定理容易导致不正确的过小分割。



归一化割

- 采用“分离”测度来计算图中连接到所有节点总边的部分代价，定义归一化割为：

$$Ncut(A, B) = \frac{cut(A, B)}{assoc(A, V)} + \frac{cut(A, B)}{assoc(B, V)}$$

- 其中：

$$assoc(A, V) = \sum_{u \in A, z \in V} w(u, z)$$
$$assoc(B, V) = \sum_{v \in B, z \in V} w(v, z)$$

- 无论 $cut(A, B)$ 为多少， $Ncut(A, B)$ 总是大于等于1。

- 定义：

$$Nassoc(A, B) = \frac{assoc(A, A)}{assoc(A, V)} + \frac{assoc(B, B)}{assoc(B, V)}$$

- 则有

$$Ncut(A, B) = 2 - Nassoc(A, B)$$

- 说明最小化归一化割的时候会最大化集内节点到全图的权重比。

计算最小图割

- NP hard 问题
- Shi 和Malik [2000]通过把最小化表示为表示为一个广义的本征值问题，求得最小化Ncut的一个离散近似解。



a b c

FIGURE 10.56 (a) Image of size 600×600 pixels. (b) Image smoothed with a 25×25 box kernel. (c) Graph cut segmentation obtained by specifying two regions.


$$w(i, j) = \begin{cases} e^{-\frac{[I(n_i) - I(n_j)]^2}{\sigma_I^2}} e^{-\frac{\text{dist}(n_i, n_j)}{\sigma_d^2}} & \text{if } \text{dist}(n_i, n_j) < r \\ 0 & \text{otherwise} \end{cases}$$

用形态学分水岭的分割


- 三种主要概念的分割：边缘检测（需要后处理连接）、阈值处理（速度快）、区域生长（连续性好），各有优缺点。
- 形态学分水岭分割将以上三种方法中的很多概念进行了具体化，能产生更稳定的分割结果。包括连接的分割边界。为在分割中结合**基于知识的约束**提供了一个简单的框架。
- 主要应用之一是从背景中提取近乎一致的前景，**经常应用于一幅图像的梯度图**，而不是图像本身。汇水盆地的**区域最小值**就可以对应于**感兴趣物体的较小梯度值**。

概念示意

地形俯视图



分水岭算法概念示意（ctd）



e f
g h

FIGURE 10.54
(Continued)
(e) Result of further flooding.
(f) Beginning of merging of water from two catchment basins (a short dam was built between them). (g) Longer dams. (h) Final watershed (segmentation) lines.
(Courtesy of Dr. S. Beucher, CMM/Ecole des Mines de Paris.)

结果的一条重要性质是：
分水线组成一条连通的路径。

水坝构建

- 水坝的构造以二值图像为基础。构建分离二元点集的水坝的最简单方法是使用形态学膨胀。
- 所有水坝的高度通常设置为1加上图像中允许的最大灰度值。




图 10.55 (a) 第 $n-1$ 步淹没处，两个部分淹没的汇水盆地；(b) 在淹没的第 n 步处，显示水已在两个盆地间溢出；(c) 用于膨胀的结构元；(d) 膨胀结果和水坝构建


分水岭分割算法 (I)

- 令 $M_1, M_2, \dots, M_R$ 是表示图像 $g(x, y)$ 的区域最小值点的集合, $C(M_i)$ 是与区域最小值 M_i 相联系的汇水盆地中的点坐标集。 $T(n)$ 表示满足 $g(s, t) < n$ 的坐标 (s, t) 的集合, 即: $T(n) = \{(s, t) | g(s, t) < n\}$
- 令 $C_n(M_i) = C(M_i) \cap T[n]$, 则 $C[n] = \bigcup_{i=1}^R C_n(M_i)$, 可以证明: $C[n-1]$ 中的每个连通分量都包含在 $\mathbf{T[n]}$ 的连通分量中。
- 算法使用 $C[\min+1] = T[\min+1]$ 来初始化, 然后进行递归处理, 由 $C[n-1]$ 计算 $C[n]$ 。

分水岭分割算法（II）

- 由 $C[n-1]$ 计算 $C[n]$ 的过程：
 - 令 Q 表示 $T[n]$ 中的连通分量的集合，对于每个连通分量 $q \in Q[n]$ ，有如下三种可能：
 - 1. $q \cap C[n-1]$ 为空集；（遇到一个新的最小值（盆地））
 - 2. $q \cap C[n-1]$ 包含 $C[n-1]$ 的一个连通分量；（ q 位于某些局部最小值的汇水盆地）
 - 3. $q \cap C[n-1]$ 包含 $C[n-1]$ 的一个以上连通分量。（遇到了分隔山脊线，必须构筑水坝），采用元素为1，大小为 3×3 的结构元来膨胀 $q \cap C[n-1]$ 且膨胀被限制到 q 时（测地膨胀），可以构建一座1个像素宽的水坝。
 - 根据 $g(x, y)$ 的直方图，可以确定算法中的 **min** 和 **max** 等参数，提高计算效率。

分水岭分割算法示例




a	b
c	d

FIGURE 10.56

(a) Image of blobs.
(b) Image gradient.
(c) Watershed lines.
(d) Watershed lines
superimposed on
original image.
(Courtesy of Dr.
S. Beucher,
CMM/Ecole des
Mines de Paris.)

分水岭分割算法的局限性

- 通常会由于噪声和梯度的其他局部不规则性造成过度分割。



a b


FIGURE 10.57
(a) Electrophoresis image. (b) Result of applying the watershed segmentation algorithm to the gradient image. Oversegmentation is evident. (Courtesy of Dr. S. Beucher, CMM/Ecole des Mines de Paris.)

- 一个原因：存在着大量潜在的最小值。可以用平滑滤波器对图像进行过滤。
- 用标记约束感兴趣区域

标记的使用

- 与**感兴趣物体相联系**的标记称为**内部标记**，与背景相关联的标记称为外部标记。
- 选择标记的典型过程分为两步：（1）预处理（平滑滤波器）；（2）定义标记必须满足的准则集合。
- 一种定义内部标记的定义为（**同时满足**）：（1）被更高“海拔”点包围的区域；（2）区域中形成一个连通分量的那些点；（3）连通分量中所有点有相同灰度值。
 - （**不限于这些定义，可以用尺寸、形状、位置等与分割有关的先验知识来做定义，人类先验知识的指导**）
- 对内部标记，在允许的区域最小值限制下对**平滑后**的图像应用分水岭算法，得到的分水线定位为**外部标记**。
- 将外部标记分割的每个区域再划分为两个部分：单个物体及其背景。

标记以及基于标记的分割



a b

FIGURE 10.58 (a) Image showing internal markers (light gray regions) and external markers (watershed lines). (b) Result of segmentation. Note the improvement over Fig. 10.47(b). (Courtesy of Dr. S. Beucher, CMM/Ecole des Mines de Paris.)

分割中运动的应用

- 运动是人类和其他任何动物从无关细节背景中提取感兴趣物体或区域的强有力的提示。
- 在成像应用中，运动来自传感器和正被观看的场景间的相对位移。

- 空间域技术

- 差值图
$$d_{ij}(x, y) = \begin{cases} 1, & |f(x, y, t_i) - f(x, y, t_j)| > T \\ 0, & \text{Others.} \end{cases}$$

- 为1的像素通常是由物体运动造成的，也可能由噪声造成。

- 累积差值图

累积差值图

- 一幅累积差值图像（**ADI**）是通过将参考图像与序列中每幅后续图像进行比较形成的。
- 当参考图像和序列中一幅图像之间在某个像素位置上出现一次差异时，累积图像中每个像素位置的计数器计数一次。
- 有三类累积差值图，绝对**ADI**、正**ADI**和负**ADI**。**R**为参考图像。

$$A_k(x, y) = \begin{cases} A_{k-1}(x, y) + 1, & |R(x, y) - f(x, y, k)| > T \\ A_{k-1}(x, y), & \text{Others} \end{cases}$$
$$P_k(x, y) = \begin{cases} P_{k-1}(x, y) + 1, & [R(x, y) - f(x, y, k)] > T \\ P_{k-1}(x, y), & \text{Others} \end{cases}$$
$$N_k(x, y) = \begin{cases} N_{k-1}(x, y) + 1, & [R(x, y) - f(x, y, k)] < -T \\ N_{k-1}(x, y), & \text{Others} \end{cases}$$

其中： $R(x, y) = f(x, y, 1)$

ADI示例

当运动物体灰度大于背景时：

- 正**ADI**的非零区域等于运动物体的大小；
- 正**ADI**的位置对应于参考帧中运动物体的位置；
- 当运动物体完全移出参考帧物体时，正**ADI**的面积不再变化；
- 物体的运动方向和速度可以由绝对**ADI**和负**ADI**中的值决定。



a b c

FIGURE 10.59 ADIs of a rectangular object moving in a southeasterly direction. (a) Absolute ADI. (b) Positive ADI. (c) Negative ADI.

用ADI建立参考图像示例

- 很多时候需要根据一组包含一个或者多个运动物体的图像来构建一幅参考图像；
- 通过监视**ADI**的变化，当一个物体完全移出其参考帧的位置时，可以由当前帧中的背景复制到最初被参考帧中物体占据的位置，创建一幅仅包含静止分量的参考图像。



a b c

FIGURE 10.60 Building a static reference image. (a) and (b) Two frames in a sequence. (c) Eastbound automobile subtracted from (a) and the background restored from the corresponding area in (b). (Jain and Jain.)

作业

- 书面作业：
- **10.3, 10.6, 10.25, 10.31, 10.34, 10.49**
- 上机作业（二选1）：
 - 1.利用霍夫变换实现一幅图像中的直线检测；
 - 2.使用**otsu**方法实现一幅图像的最佳全局阈值分割。