


第9章 特征提取




概述

- 目标分割之后是特征提取，包括特征检测和特征描述。
- 目标表示
 - 对目标的直接的、具体的表示
 - **表示**一个区域主要有**两种选择**：1.外部特征，如边界；2.内部特征，如内部组成像素。
- 目标的描述
 - 根据所选择的表示方式，计算出目标的特征参数以及目标间的关系
 - 可用于对目标的分析和识别
 - 关键是选择合适的特征以及精确测量这些特征
 - 应该**尽可能地对目标大小、平移和旋转不敏感**。



表示

- 边界追踪（边界上的点按某种次序排序，Moore边界追踪法）
 - 给定一个二值区域R或其边界，追踪R的边界算法：
 - 1. 起始点 b_0 为左上角标记为1的点， c_0 为 b_0 西侧的邻点（总为背景点）。从 c_0 开始按照顺时针方向考察 b_0 的8个邻点。若 b_1 是所遇到的值为1的第一个邻点， c_1 是序列总 b_1 之前的点。存储 b_0 和 b_1 ;
 - 2. 令 $b=b_1, c=c_1$ 。
 - 3. 从 c 开始顺时针方向前进，令 b 的8个邻点为 $n_1, n_2, \dots, n_8$ 。找到标1的第一个 $n(k)$ 。令 $b=n(k), c=n(k-1)$ 。
 - 重复步骤3，直到 $b=b_0$ ，且找到的下一个边界点为 b_1 （重要附加条件）。

边界追踪算法



为避免错误停止，停止规则中附加规定的重要性。




a b c


FIGURE 11.2 Illustration of an erroneous result when the stopping rule is such that boundary-following stops when the starting point, b_0 , is encountered again.

边界表达

- 边界链码（弗里曼链码）
 - 是关于边界点方向的编码
 - 边界的链码可用边界跟踪算法得到
 - 关于形状的特征，如周长、曲率等可直接用链码得到
 - 链码一般不能直接用于目标识别
 - (1) 链码串常常很长
 - (2) 噪声干扰大





(a) 4方向链码




(b) 8方向链码

方向链码



链码:22121011011030333323




链码:443212120766665

边界及其链码

- 目标平移，则链码不变
- 链码的每个方向码加上一个常数（以8或4取模），相当于目标旋转。
- 对8方向链码：
 - 加上奇数：旋转 45° 的倍数；
 - 加上偶数：旋转 90° 的倍数
- 若链码的起点不同
 - 同一目标会有不同的链码
 - 头尾相接后的循环链码是一样的
 - 起点归一化方法 :整数值为最小
- 目标的尺寸改变也会引起链码的变化
 - 尺寸归一化 :通过改变取样网格的大小来实现


- 目标旋转，则链码会发生变化
 - 但链码的一阶差分形成的码(差分链码)不变
 - 旋转归一化:差分链码



链码与目标旋转

	图(a)	旋转90° 度的图(b)
链码	1 0 1 0 3 3 2 2	2 1 2 1 0 0 3 3
差分链码	3 3 1 3 3 0 3 0	3 3 1 3 3 0 3 0

边界链码及其变化



a b c
d e f

获得的8方向（最小）链码：00006066666666444444242222202202

FIGURE 11.5 (a) Noisy image. (b) Image smoothed with a 9×9 averaging mask. (c) Smoothed image, thresholded using Otsu's method. (d) Longest outer boundary of (c). (e) Subsampled boundary (the points are shown enlarged for clarity). (f) Connected points from (e).

使用最小周长多边形（MPP）的多边形近似

方法的直观概念表示：




FIGURE 11.6 (a) An object boundary (black curve). (b) Boundary enclosed by cells (in gray). (c) Minimum-perimeter polygon obtained by allowing the boundary to shrink. The vertices of the polygon are created by the corners of the inner and outer walls of the gray region.

MPP的基本思想

- 内墙的凸和外墙的凹顶点才能成为MPP的顶点





FIGURE 11.7 (a) Region (dark gray) resulting from enclosing the original boundary by cells (see Fig. 11.6). (b) Convex (white dots) and concave (black dots) vertices obtained by following the boundary of the dark gray region in the counterclockwise direction. (c) Concave vertices (black dots) displaced to their diagonal mirror locations in the outer wall of the bounding region; the convex vertices are not changed. The MPP (black boundary) is superimposed for reference.

MPP算法结果示例

不同量化方形单元得到的MPP，
量化越大，顶点
数越少。



a	b	c
d	e	f
g	h	i

FIGURE 11.8


(a) 566×566 binary image.
(b) 8-connected boundary.
(c) through (i), MPPs obtained using square cells of sizes 2, 3, 4, 6, 8, 16, and 32, respectively (the vertices were joined by straight lines for display). The number of boundary points in (b) is 1900. The numbers of vertices in (c) through (i) are 206, 160, 127, 92, 66, 32, and 13, respectively.

其他（更简单） 多边形方法

- 1. 聚合技术


- 基于平均误差来聚合边界点。例如：沿着一条边界来聚合一些点，直到拟合这些聚合点的直线的最小均方误差超过一个预设的阈值。记录直线，并继续开始新的直线拟合。
- 主要缺点是得到的近似顶点并不重视对应于原始边界中的较大形变（如拐角）。

- 2. 基于分裂（split）的最小误差线段逼近




- 标记图

- 标记 (signature) 是将二维的边界化为一维函数的形式
 - 最简单的标记是先求出形心，然后用边界点与形心的距离作为角度的函数，就得到一种标记



(a)圆的标记




(b)正方形的标记

- 这种方法产生的标记**不受目标平移的影响**
 - 目标的**尺度变换会改变标记后的幅度**
 - 目标的**旋转会影响角度测量的起点**

如果：

- 对标记作归一化处理，如使最大值为1，则不会受尺度变换的影响；
- 如果起始角的选取是与目标形状有关的，如选用最远边界点，或用主轴方向（转动惯量最小）作起始角，则目标的旋转不会影响标记的结果。

两个区域的 标记图




a b
c d
e f


FIGURE 11.11 Two binary regions, their external boundaries, and their corresponding $r(\theta)$ signatures. The horizontal axes in (e) and (f) correspond to angles from 0° to 360° , in increments of 1° .

• 边界线段

- 将边界分成数段，并简化对每段的表示，以减少复杂度
- 对于非凸的边界，可借助凸包概念将边界分段
 - 区域S，它的逼近凸包H是包含S的最小凸多边形，把 $D=H-S$ 叫作S的凸残差
 - D的不同区域对应的边界就是边界段，H与边界分离点为边界的分段点。与区域大小和方向无关。



(a) 区域S和它凸残差D



(b) 被分割的边界


一种边界段分割方法

- 细化与骨架化

- 细化操作是把区域的截面宽度缩到最小，即**单像素宽度**，也就是把物体变细，直到出现**最小的像点连通性**


- 细化操作

- 沿着边界一层一层向区域内部收缩
 - **孤点和孤端点都不能被删去，以保持连通性**
 - **顺序不同，结果不同**
(左、右、上、下，跟踪边界)
 - 用于**文字识别**




目标的细化


- 骨架化——中轴变换 (medial axis transform, MAT)
 - 中轴变换可用**火烧草地**来比拟：
在草地边界上同时点火，火相遇（熄灭）的点就是中轴




(a)



(b)



(c)




(d)

用欧氏距离的中轴变换示例

- 中轴:

- 对于一个区域R，若边界为B，对区域中每一点P，我们在B上搜索与它最近的点，若能找到多于一个同样距离的最近点，则P属于R的中轴或称骨架
- 在R内作与边界有两个以上切点的内切圆，则所有这些圆的圆心的集合就是中轴
- 对于中轴与边界相连的区域，可以通过以每个骨架点为中心的圆来重建区域，即这些圆的集合的并组成了整个区域
- 用于中轴变换的距离，除欧氏距离外，也可用其它距离
- 相对于细化，中轴变换的定义更严格，实用中可不区分



由距离变换等效地得到骨架

- 距离变换：找每个像素与标记为1的像素的最小距离
- 图像的骨架等效于距离变换的脊；
- 脊是局部极大值的集合；
- 相比细化方法，距离变换往往容易产生连续的骨架

a b
c d
e f

FIGURE 11.13
(a) A small image and (b) its distance transform. Note that all 1-valued pixels in (a) have corresponding 0's in (b). (c) A small image, and (d) the distance transform of its complement. (e) A larger image, and (f) the distance transform of its complement. The Euclidean distance was used throughout.



0	0	0	0	0
0	1	1	1	0
0	1	1	1	0
0	0	0	0	0

0	0	0	0	0	0	0	0	0
0	1	1	1	1	1	1	1	0
0	1	1	1	1	1	1	1	0
0	1	1	1	1	1	1	1	0
0	1	1	1	1	1	1	1	0
0	1	1	1	1	1	1	1	0
0	0	0	0	0	0	0	0	0

1.41	1	1	1	1.41
1	0	0	0	1
1	0	0	0	1
1.41	1	1	1	1.41

0	0	0	0	0	0	0	0	0
0	1	1	1	1	1	1	1	0
0	1	2	2	2	2	2	1	0
0	1	2	3	3	3	2	1	0
0	1	2	2	2	2	2	1	0
0	1	1	1	1	1	1	1	0
0	0	0	0	0	0	0	0	0





骨架化示例

a	b
c	d


FIGURE 11.14

(a) Thresholded image of blood vessels.

(b) Skeleton obtained by thinning, shown superimposed on the image (note the spurs).


(c) Result of 40 passes of spur removal.

(d) Skeleton obtained using the distance transform.



边界描述子


- 简单描述（测量特征值）
 - 1.边界的长度
 - 边界所包围区域的周长
 - (1)目标的边界是8连通的，则边界的长度可用八链码长度来近似
 - (2) 8链码中代表斜向的奇数链码的长度计为 $\sqrt{2}$ 。这种方法估计的长度比前一种方法误差小些。



区域的边界

• 2.边界的直径

- 边界上相隔最远的二点间的距离，即这二点间的直线长度
- 也称为边界的主轴或长轴
- 其长度和方向是描述边界的一种特征
- 对长度的测量常用欧氏距离，也可用街区距离（水平和垂直距离之和）或棋盘距离： $D_8(p,q) = \max(|X_p - X_q|, |Y_p - Y_q|)$



- 3.曲率

- 边界的切线方向沿曲线的变化率


$$K = \frac{d\alpha}{ds} = \frac{y''}{(1 + y'^2)^{\frac{3}{2}}}$$

- 数字图像

- 可先对边界进行分段拟合，再计算曲率，
- 可通过估计边界上的切向和弧长来近似计算曲率

- 曲率半径

- 是相同曲率的圆的半径，表征了边界的弯曲程度
- 曲率与半径互为倒数



边界的曲率

$$R = \frac{1}{|K|} = \left| \frac{ds}{d\alpha} \right|$$

证明:

$$y = f(x)$$

$$\operatorname{tg} \alpha = \frac{dy}{dx} = y'$$


$$K = \frac{d\alpha}{ds} = \frac{d\alpha}{d(\operatorname{tg} \alpha)} \frac{d(\operatorname{tg} \alpha)}{dx} \frac{dx}{ds}$$

$$\frac{d(\operatorname{tg} \alpha)}{d\alpha} = 1 + \operatorname{tg}^2 \alpha = 1 + y'^2$$

$$\frac{d(\operatorname{tg} \alpha)}{dx} = \frac{dy'}{dx} = y''$$

$$\frac{ds}{dx} = \frac{\sqrt{(dx)^2 + (dy)^2}}{dx} = \sqrt{1 + y'^2}$$

$$K = \frac{d\alpha}{ds} = \frac{d\alpha}{d(\operatorname{tg} \alpha)} \frac{d(\operatorname{tg} \alpha)}{dx} \frac{dx}{ds} = \frac{y''}{(1 + y'^2)^{\frac{3}{2}}}$$




边界的曲率

- 如果沿边界的逆时针方向走，则曲率还表征了边界的凹凸性
 - 如果曲率大于零，则边界是向外凸的；（向左弯）
 - 如果曲率小于零，则边界是向内凹的；（向右弯）
 - 如果曲率为零，边界段为直线。

形状数

- 形状数：组成最小整数的差分链码（归一化）
 - 如图的4方向链码为10103322，差分码为33133030，形状数为03033133
 - 形状数是90度/45度旋转不变且与起点无关的一种边界描述
- 形状数的阶n：形状数序列的长度
 - 对于四链码，闭合曲线的形状数的阶总是偶数；
 - 对于凸形区域，四链码的阶与边界的外接矩形的周长对应



4方向链码示例

阶为4,6,8的所有形状






FIGURE 11.17
All shapes of order 4, 6, and 8. The directions are from Fig. 11.3(a), and the dot indicates the starting point.


- 用网格近似原边界包围的区域，则区域的边界可得到：
 - 阶为18的链码：000030032232221211
 - 差分码为：300031033013003130
 - 形状数为：000310330130031303




(a) 物体的边界



(b) 边界包围框



(c) 框的长度等于阶



(d) 指定阶的链码

找指定阶的形状数

傅立叶描绘子

- 设边界上有N个点，**按逆时针方向**，坐标依次为 (x_k, y_k) ， $k=0,1,\dots,N-1$ ，我们将其表示成复数形式：

$$s(k) = x_k + jy_k, \quad k=0,1,\dots,N-1$$

- $s(k)$ 的离散傅立叶变换是

$$S(u) = \frac{1}{N} \sum_{k=0}^{N-1} s(k) \exp[-j2\pi uk / N], \quad u=0,1,\dots,N-1$$


- $S(u)$ 称为边界的傅立叶描述。反变换可得到边界的坐标


$$s(k) = \sum_{u=0}^{N-1} S(u) \exp[j2\pi uk / N], \quad k=0,1,\dots,N-1$$

- 如果只利用傅立叶描述的前P个值，即舍去边界上的高频成分，则

$$s(k) = \sum_{u=0}^{P-1} S(u) \exp[j2\pi uk / N] \quad , \quad k=0,1,\dots,N-1$$

- 是对边界的近似





用付立叶描绘子重建边界的示例





FIGURE 11.20 (a) Boundary of human chromosome (2868 points). (b)–(h) Boundaries reconstructed using 1434, 286, 144, 72, 36, 18, and 8 Fourier descriptors, respectively. These numbers are approximately 50%, 10%, 5%, 2.5%, 1.25%, 0.63%, and 0.28% of 2868, respectively.

- 傅立叶描绘子在平移、旋转、尺度变换及起点不同时的影响


变 换	边 界	傅立叶描述
平移 ($\mathbf{x}_0, \mathbf{y}_0$)	$s_t(k) = s(k) + x_0 + jy_0$	$S_t(u) = S(u) + (x_0 + jy_0) \cdot \delta(u)$
旋转 (θ)	$s_r(k) = s(k) \exp(j\theta)$	$S_r(u) = S(u) \exp(j\theta)$
尺度 (C)	$s_c(k) = C \cdot s(k)$	$S_c(u) = C \cdot S(u)$
起点 ($\mathbf{k}_0$)	$s_p(k) = s(k - k_0)$	$S_p(u) = S(u) \exp(-j2\pi k_0 u / N)$

统计矩

- 对任一段边界曲线，均可将其表示成一维函数 $f(r)$ 的形式，其中 r 是任意可用的变量
- 如：边界上的点到两端所成直线的距离可作为函数值



(a) 边界线段



(b) 一维函数表示

边界线段的函数表示

- 设边界共有L点，如果将r当作随机变量，上图(b)看成是r的直方图， $f(r)$ 当作r的概率（归一化），则r的均值为

$$m = \sum_{r=1}^L r_i f(r_i) \quad r \text{的一阶矩}$$

- r的n阶中心矩为

$$\mu_n = \sum_{r=1}^L (r_i - m)^n f(r_i)$$


μ_n 与函数 $f(r)$ 的形状有直接关系，如，二阶矩描述了曲线相对于均值的分布，三阶矩描述了曲线相对于均值的对称性。

这种方法由于进行了边界的旋转，故有旋转不变性，也可通过r和 $f(r)$ 的缩放达到尺度归一化。

区域表示

- 区域表示是对分割后的目标区域的表达方法
 - 可不失真地表达整个区域的数据
 - 也可只表达从中抽取的一些代表性的数据
- 数组表示
 - 目标区域内为1，在区域外为0，称为空间占有数组
 - 缺点是占用较大的存贮空间, 特别是区域面积较大时
- 四叉树表示
 - 容易生成得到，特别是在用基于四叉树像素分块的分裂合并算法进行图像分割时，在分割过程中就可得到四叉树，只是不必作合并操作；

• 四叉树



四叉树表达


- 树上的结点分三种类型：
 - (1) 目标结点 (白色)
 - (2) 背景结点 (深色)
 - (3) 混合结点 (浅色) ——可展开

区域描述子

- 简单描述

- 1. 区域面积

$$A = \sum_{(x,y) \in R} 1$$




区域面积计算

- 2. 区域重心(区域形心)

$$\bar{x} = \frac{1}{A} \sum_{(x,y) \in R} x \quad \bar{y} = \frac{1}{A} \sum_{(x,y) \in R} y$$

- A是区域R内的像素点数，即面积

- 使用面积计算从图像中提取信息
(从各区域灯光面积占所有区域面积之比中可估计电能消耗等信息)





- 圆度率（旋转、尺度不变）

- 区域的周长为P，面积为A，则形状因子（或叫圆形度）为：

$$R_c = \frac{4\pi A}{P^2}$$

- 如果区域为圆形，则形状因子值最小， $R_c=1$




有相同圆度率的三个区域

(周长=12,面积=5,相同)

区域特征描述子

- 紧致度 $compactness = \frac{p^2}{A}$
 - 无量纲。圆的紧致度是 4π ，正方形的紧致度是16.
- 偏心率
 - 与给定区域有着相同二阶中心矩的一个椭圆的偏心率

$$eccentricity = \frac{c}{a} = \frac{\sqrt{a^2 - b^2}}{a} = \sqrt{1 - (b/a)^2} \quad a \geq b$$




主轴是协方差矩阵的特征值所对应的特征向量：

$$C = \frac{1}{K-1} \sum_{k=1}^K (z_k - \bar{z})(z_k - \bar{z})^T$$

$$eccentricity = \frac{\sqrt{\lambda_2^2 - \lambda_1^2}}{\lambda_2} = \sqrt{1 - (\lambda_1/\lambda_2)^2} \quad \lambda_2 \geq \lambda_1$$

特征描述子的比较

Descriptor				
<i>Compactness</i>	10.1701	42.2442	15.9836	13.2308
<i>Circularity</i>	1.2356	0.2975	0.7862	0.9478
<i>Eccentricity</i>	0.0411	0.0636	0	0.8117



- 拓扑描述符

- 图形的拓扑性质


- 是指那些变形不发生撕裂或连接变化的情况下，**不因图像变形而改变的性质**

- 区域的二种拓扑性质：


- 区域的连通数C
 - 区域的孔数H

- 欧拉数（Euler number）——另一种拓扑性质


- $E = C - H$



(a) $C=1, H=2, E=-1$





(b) $C=1, H=1, E=0$



(c) $C=1, H=2, E=-1$


区域的连通性

- 对于一个直线段构成的区域（称为多变形网络）
 - 若顶点数为 V ，边数为 Q ，面数为 F
 - 则有： $V - Q + F = E = C - H = E$
- 例： $V=6$ ， $Q=9$ ， $F=2$ ， $C=1$ ， $H=2$
 - 欧拉数 $E = -1$



使用最大连通分量在已分割图像中提取感兴趣目标

- (c)图中孔洞数量代表了河流中的陆地块数量；
- (d) 想要测量合理的每条支流的长度时，可以使用连通分量的骨架。



a	b
c	d

FIGURE 11.27
(a) Infrared image of the Washington, D.C. area.
(b) Thresholded image. (c) The largest connected component of (b). Skeleton of (c).

纹理

- 区域描述的一个重要方法是量化该区域的纹理内容。虽然不存在纹理的正式定义，但在直觉上，这类描述子提供了诸如平滑度、粗糙度和规律性等特性的度量。
- 三种主要的纹理描述方法：统计方法，结构方法和频谱方法。
 - 统计方法生成诸如平滑、粗糙、粒状等的纹理特征；
 - 结构技术处理像元的排列等；
 - 频谱技术基于傅里叶频谱特性，主要用于检测图像的全局周期性，方法是识别图像中的高能量的窄波峰。

统计方法

- 描述纹理最简单的方法之一是使用一幅图像或一个区域的灰度直方图的统计矩。
- 令 z_i 表示灰度随机变量, $p(z_i)$ 表示相应的直方图, 关于其均值的 n 阶中心矩为:

$$\mu_n(z) = \sum_{i=0}^{L-1} (z_i - m)^n p(z_i)$$

- 其中:

$$m = \sum_{i=0}^{L-1} z_i p(z_i)$$

- 因此有: $\mu_0 = 1$, $\mu_1 = 0$, $\mu_2 = \sigma^2(z)$ 是对比度的度量

- $\mu_3(z) = \sum_{i=0}^{L-1} (z_i - m)^3 p(z_i)$ 是直方图倾斜度的度量

统计方法

- 相对平滑度的描绘子:

$$R(z) = 1 - \frac{1}{1 + \sigma^2(z)}$$

- 一致性度量:

- 熵度量: $U(z) = \sum_{i=0}^{L-1} p^2(z_i)$ 对恒定灰度图像具有最大值1

-

$$e(z) = - \sum_{i=0}^{L-1} p(z_i) \log_2 p(z_i) \quad \text{对灰度恒定图像, 值为零。}$$

纹理描述子示例





TABLE 12.2

Statistical texture measures for the subimages in Fig. 12.29.

Texture	Mean	Standard deviation	R (normalized)	3rd moment	Uniformity	Entropy
Smooth	82.64	11.79	0.002	-0.105	0.026	5.434
Coarse	143.56	74.63	0.079	-0.151	0.005	7.783
Regular	99.72	33.73	0.017	0.750	0.013	6.674

灰度共生矩阵

- 将位置和灰度一起考虑并描述的方法
 - 在一幅图像中规定一种对于两个像素间的位置关系（包括方向和距离），设有这种关系的两个像素的灰度值分别为 g_i 和 g_j ，
 - **共生矩阵**：利用这些像素对得到的**二维直方图**
 - 共生矩阵A的每个元素 a_{ij} 是具有灰度 g_i 和 g_j 的像素对在图像上出现的数目。
 - **例**： g_j 是 g_i 的右下一个像素



(a) 图像数据

$$A = \begin{bmatrix} a_{00} & a_{01} & a_{02} \\ a_{10} & a_{11} & a_{12} \\ a_{20} & a_{21} & a_{22} \end{bmatrix} = \begin{bmatrix} 4 & 2 & 0 \\ 2 & 3 & 2 \\ 1 & 2 & 0 \end{bmatrix}$$


$G_j = 0 \quad 1 \quad 2$
 $G_i = 0 \quad 1 \quad 2$

矩阵尺寸跟灰度级数目有关





- 归一化共生矩阵可定义为：

$$P(g_1, g_2) = \frac{\#\{[(x_1, y_1), (x_2, y_2)] \in S \mid f(x_1, y_1) = g_1 \ \& \ f(x_2, y_2) = g_2\}}{\#S}$$

- S为目标区域R中具有指定空间关系的像素对的集合
- #表示数量
- 右边分子上表示具有指定关系，且灰度值分为 g_1 和 g_2 的像素对数
- 分母为具有指定关系的像素对的总数
- 这样得到的P是归一化值。



示例图像及其灰度共生矩阵 (右侧紧邻像素位置)



正弦波
的对称
性导致

- 利用共生矩阵定义的几个常用的纹理特征

- 1. 最大概率

$$W_P = \max_{g_1, g_2} P(g_1, g_2)$$

- 表示P的最强响应（哪种模式出现得最多）

- 2. 一致性，或称纹理二阶矩

$$W_M = \sum_{g_1} \sum_{g_2} (P(g_1, g_2))^2$$

- 当所有的 $P(g_1, g_2)$ 相等时， W_M 有最小值，对应图像的纹理较丰富

- 3. 熵

$$W_E = - \sum_{g_1} \sum_{g_2} P(g_1, g_2) \log P(g_1, g_2)$$

- 当所有的 $P(g_1, g_2)$ 相等时， W_E 有最大值。

• 4. 对比度

$$W_I = \sum_{g_1} \sum_{g_2} (g_1 - g_2)^2 P(g_1, g_2)$$

一个像素在整个图像上与其邻居间的灰度对比的度量。

• 5. 同质性

$$W_H = \sum_{g_1} \sum_{g_2} \frac{P(g_1, g_2)}{1 + |g_1 - g_2|}$$

- 在图像平坦时，共生矩阵集中在 g_1 和 g_2 相近的对角线上，该指标具有较高值。

• 6 相关


$$\sum_i \sum_j \frac{(i - m_r)(j - m_c) p_{ij}}{\sigma_r \sigma_c}$$

- 描述一个像素在整个图像上与其邻居相关程度的度量，其中

$$m_r = \sum_{i=1}^K i \sum_{j=1}^K p_{ij} \quad m_c = \sum_{j=1}^K j \sum_{i=1}^K p_{ij} \quad \sigma_r^2 = \sum_{i=1}^K (i - m_r)^2 \sum_{j=1}^K p_{ij} \quad \sigma_c^2 = \sum_{j=1}^K (j - m_c)^2 \sum_{i=1}^K p_{ij}$$

分别为行列计算的均值和方差。

各种描述子的值示例



相关描述子的值随着水平偏移距离的变化

TABLE 12.4

Descriptors evaluated using the co-occurrence matrices displayed as images in Fig. 12.32.

Normalized Co-occurrence Matrix	Maximum Probability	Correlation	Contrast	Uniformity	Homogeneity	Entropy
G_1/n_1	0.00006	-0.0005	10838	0.00002	0.0366	15.75
G_2/n_2	0.01500	0.9650	00570	0.01230	0.0824	06.43
G_3/n_3	0.06860	0.8798	01356	0.00480	0.2048	13.58




FIGURE 11.32 Values of the correlation descriptor as a function of offset (distance between “adjacent” pixels) corresponding to the (a) noisy, (b) sinusoidal, and (c) circuit board images in Fig. 11.30.


结构方法

- 将物体的复杂结构分解成一定的**基元(基本元素)**，可**利用基元的组成规则描述物体**
- 对图像上多种目标，之间关系也可用一定的规则描述
 - 例：定义如下基元：a:→,b:↓,c:←,d:↑
 - ab表示a和b这两个有向线段头尾相接
 - a^n 表示有n个a代表的水平有向线段相连接
 - 则 $a^n b^n$ 表示的是边长为n个单位的一个直角, $a^n b^n c^n d^n$ 可表示边长为n个单位的矩形
 - 若**定义重写（替换）规则**： $S \rightarrow aSb$, $S \rightarrow ab$,

$$S \rightarrow aSb \rightarrow aaSbb \rightarrow aaaSbbb \rightarrow \dots \rightarrow a^n b^n$$

可表示任意长度的一直角

- 如果我们定义另一组重写规则： $S \rightarrow aA$, $A \rightarrow bS$, $A \rightarrow b$
 - 则 $S \rightarrow aA \rightarrow abS \rightarrow abaA \rightarrow ababS \rightarrow \cdots \rightarrow (ab)^n$
- S称为起始符，S和A为非终止符（相当于变量）
- 规则、起始符、非终止符和基元构成了一种文法
- 文法可作为区域或目标的一种描述。




(a) a^3b^3 描述的图形

(b) $ababab$ 描述的图形

串描述的图形


频谱方法

- 图像上周期性和方向性的纹理在频谱上有相应的表现
 - 1.周期性纹理在频谱上有相应的能量集中区域
 - 2.纹理的方向在频谱上表现为能量集中区域所在的方向
- 将频谱表示成极坐标形式： $S(r, \theta)$
 - 对于每个方向 θ ，频谱的分布可用一维函数 $S_\theta(r)$ 表示
 - 对于每个指定 r 的圆环上，频谱的分布也可用一维函数 $S_r(\theta)$ 表示
 - 在 r 半径上的总的能量为
$$S(r) = \sum_{\theta=0}^{\pi} S_\theta(r)$$
- 在 θ 方向的总能量为
$$S(\theta) = \sum_{r=1}^{R_0} S_r(\theta)$$





频谱纹理

粗糙背景的
周期性纹理



谱方法示例

- 下图的 $S(r)$ 有两个次尖峰，对应亮垂直排列目标与背景的纹理周期重复；
- 上图的 $S(\theta)$ 有周期性。



对应于左边两幅图的 $S(r)$ 和 $S(\theta)$

不变矩

- 一幅数字图像 $f(x,y)$ ，它的 $p+q$ 阶矩定义:

$$m_{pq} = \sum_x \sum_y x^p y^q f(x, y)$$

- 可以证明

- m_{pq} 唯一地被 $f(x,y)$ 所确定
- 所有非负整数 p 和 q 得到的 m_{pq} 无限集也完全确定了 $f(x,y)$

- 图像 $f(x,y)$ 的 $p+q$ 阶中心矩定义

$$\mu_{pq} = \sum_x \sum_y (x - \bar{x})^p (y - \bar{y})^q f(x, y)$$

- 其中 $\bar{x} = m_{10} / m_{00}$ $\bar{y} = m_{01} / m_{00}$
 - 是图像的重心坐标

- 前三阶中心矩可用下式计算

$$\mu_{00} = m_{00}$$

$$\mu_{02} = m_{02} - \bar{y}m_{01}$$

$$\mu_{10} = 0$$

$$\mu_{30} = m_{30} - 3\bar{x}m_{20} + 2\bar{x}^2m_{10}$$

$$\mu_{01} = 0$$

$$\mu_{03} = m_{03} - 3\bar{y}m_{02} + 2\bar{y}^2m_{01}$$

$$\mu_{11} = m_{11} - \bar{y}m_{10}$$

$$\mu_{21} = m_{21} - 2\bar{x}m_{11} - \bar{y}m_{20} + 2\bar{x}^2m_{01}$$

$$\mu_{20} = m_{20} - \bar{x}m_{10}$$

$$\mu_{12} = m_{12} - 2\bar{y}m_{11} - \bar{x}m_{02} + 2\bar{y}^2m_{10}$$

- $f(x,y)$ 的归一化中心矩

$$\eta_{pq} = \frac{\mu_{pq}}{\mu_{00}^r}$$

- 其中 $r = \frac{p+q}{2} + 1$, $p+q=2,3,\dots$

- 使二阶中心矩 μ_{11} 变得最小的旋转角 θ 可由下式得出

$$\tan 2\theta = \frac{2\mu_{11}}{\mu_{20} - \mu_{02}}$$

- 若 x,y 轴旋转 θ 角得坐标轴 x',y' , 称为该目标的主轴
 - 如果目标在计算矩前旋转 θ 角, 或相对于 x',y' 轴计算矩, 则矩具有旋转不变性

- 由归一化的二阶和三阶中心矩可得到如下7个对连续图像平移、旋转和尺度变换不变的矩：

$$\phi_1 = \eta_{20} + \eta_{02}$$

$$\phi_2 = (\eta_{20} - \eta_{02})^2 + 4\eta_{11}^2$$

$$\phi_3 = (\eta_{30} - 3\eta_{12})^2 + (3\eta_{21} - \eta_{03})^2$$


$$\phi_4 = (\eta_{30} + \eta_{12})^2 + (\eta_{21} + \eta_{03})^2$$

$$\begin{aligned} \phi_5 = & (\eta_{30} - 3\eta_{12})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] \\ & + (3\eta_{21} - \eta_{03})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \end{aligned}$$

$$\phi_6 = (\eta_{20} - \eta_{02})[(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] + 4\eta_{11}(\eta_{30} + \eta_{12})(\eta_{21} + \eta_{03})$$

$$\begin{aligned} \phi_7 = & (3\eta_{21} - \eta_{03})(\eta_{30} + \eta_{12})[(\eta_{30} + \eta_{12})^2 - 3(\eta_{21} + \eta_{03})^2] \\ & + (3\eta_{12} - \eta_{30})(\eta_{21} + \eta_{03})[3(\eta_{30} + \eta_{12})^2 - (\eta_{21} + \eta_{03})^2] \end{aligned}$$

- 由于 $\phi_7^2 + \phi_5^2 = \phi_3\phi_4^3$ ，所以上述7个不变矩只用6个就可



Moment Invariant	Original Image	Translated	Half Size	Mirrored	Rotated 45°	Rotated 90°
ϕ_1	2.8662	2.8662	2.8664	2.8662	2.8661	2.8662
ϕ_2	7.1265	7.1265	7.1257	7.1265	7.1266	7.1265
ϕ_3	10.4109	10.4109	10.4047	10.4109	10.4115	10.4109
ϕ_4	10.3742	10.3742	10.3719	10.3742	10.3742	10.3742
ϕ_5	21.3674	21.3674	21.3924	21.3674	21.3663	21.3674
ϕ_6	13.9417	13.9417	13.9383	13.9417	13.9417	13.9417
ϕ_7	-20.7809	-20.7809	-20.7724	20.7809	-20.7813	-20.7809

使用主分量进行描绘

- 采用霍特林 (Hotelling) 变换, 也常称为特征值变换、主分量变换
- 随机矢量 $\bar{x} = [x_1 \ x_2 \ \dots \ x_N]^T$
- 随机抽取M个矢量 $\bar{x}_k, k=1,2,\dots,M$, 称为随机矢量的M个样本

$$\bar{x}_k = [x_1^k \ x_2^k \ \dots \ x_N^k]^T, \ k=1,2,\dots,M$$

- 均值矢量 $\bar{\mathbf{m}}_x = E\{\bar{\mathbf{x}}\}$
- 协方差矩阵 $\mathbf{C}_x = E\{(\bar{\mathbf{x}} - \bar{\mathbf{m}}_x)(\bar{\mathbf{x}} - \bar{\mathbf{m}}_x)^T\}$
 - 其中矩阵元素 $\sigma_{i,j,x} = E\{(x_i - m_{i,x})(x_j - m_{j,x})\}$ 为 x_i 和 x_j 的协方差
- 自相关矩阵 $\mathbf{R}_x = E\{\bar{\mathbf{x}} \bar{\mathbf{x}}^T\}$
 - 有 $\mathbf{C}_x = \mathbf{R}_x - \bar{\mathbf{m}}_x \bar{\mathbf{m}}_x^T$
- 可用M个样本估计均值矢量和协方差矩阵

$$\bar{\mathbf{m}}_x = \frac{1}{M} \sum_{k=1}^M \bar{\mathbf{x}}_k$$

$$\mathbf{C}_x = \frac{1}{M} \sum_{k=1}^M \bar{\mathbf{x}}_k \bar{\mathbf{x}}_k^T - \bar{\mathbf{m}}_x \bar{\mathbf{m}}_x^T$$

- 例：设有随机矢量的4个样本：

$\bar{x}_1 = [0 \ 0 \ 0]^T$, $\bar{x}_2 = [1 \ 0 \ 0]^T$, $\bar{x}_3 = [1 \ 1 \ 0]^T$, $\bar{x}_4 = [1 \ 0 \ 1]^T$, 则可根据上式估计均值矢量和协方差矩阵：

$$\bar{m}_x = \frac{1}{4} [3 \ 1 \ 1]^T$$

$$\mathbf{C}_x = \frac{1}{16} \begin{bmatrix} 3 & 1 & 1 \\ 1 & 3 & -1 \\ 1 & -1 & 3 \end{bmatrix}$$

- $N \times N$ 的矩阵 C ，存在 N 个标量 $\lambda_k, k=1,2,\dots,N$,使

$$|C - \lambda_k I| = 0$$

- λ_k 称为矩阵的特征值
- 对应 N 个特征值 λ_k 有 N 个矢量，满足： $C\bar{v}_k = \lambda_k \bar{v}_k$
 - $\bar{v}_k$ 称为矩阵 C 的特征矢量。一般特征矢量采用归一化形式。这些特征矢量构成一正交基集。
- $A = [\bar{v}_1 \quad \dots \quad \bar{v}_k \quad \dots \quad \bar{v}_N]$ 称为 C 的特征矩阵，按照特征值的大小，将对应特征向量从左向右按列排列而成。

- 霍特林变换：用矩阵 $\mathbf{C}_x$ 的特征矩阵 $\mathbf{A}$ 作线性变换

- 则
$$\begin{aligned}\bar{y} &= \mathbf{A}^T (\bar{x} - \bar{m}_x) \\ \bar{m}_y &= \mathbf{A}^T E\{(\bar{x} - \bar{m}_x)\} = 0 \\ \mathbf{C}_y &= E\{(\bar{y} - \bar{m}_y)(\bar{y} - \bar{m}_y)^T\} \\ &= E\{\mathbf{A}^T (\bar{x} - \bar{m}_x)[\mathbf{A}^T (\bar{x} - \bar{m}_x)]^T\} \\ &= E\{\mathbf{A}^T (\bar{x} - \bar{m}_x)(\bar{x} - \bar{m}_x)^T \mathbf{A}\} \\ &= \mathbf{A}^T \mathbf{C}_x \mathbf{A}\end{aligned}$$

- 故
$$\mathbf{C}_y = \begin{bmatrix} \lambda_1 & & & 0 \\ & \lambda_2 & & \\ & & \ddots & \\ 0 & & & \lambda_N \end{bmatrix}$$

有去相关作用，如
各彩色分量，一行
像素的值的的相关性

- 霍特林变换是可逆的

$$\bar{x} = (\mathbf{A}^T)^{-1} \bar{y} + \bar{m}_x$$

- 由于A的各列都是正交归一矢量，即 $\mathbf{A}^T \mathbf{A} = \mathbf{I}$ ，有 $\mathbf{A}^{-1} = \mathbf{A}^T$ ，所以

$$\bar{x} = \mathbf{A} \bar{y} + \bar{m}_x$$

- 若只取 $\mathbf{C}_x$ 的最大的K个特征值对应的特征矢量，构成N*K阶变换矩阵 $\mathbf{A}_K$ ，这样得到的是K维矢量。即变换使维数从 $\bar{x}$ 的N维降为 $\bar{y}$ 的K维

$$\bar{y} = \mathbf{A}_K^T (\bar{x} - \bar{m}_x)$$

- 重建只能得到近似值

$$\hat{\bar{x}} = \mathbf{A}_K \bar{y} + \bar{m}_x$$

- 重建后 $\hat{\bar{x}}$ 与 $\bar{x}$ 的均方误差为

$$\begin{aligned}\varepsilon &= E\{\|\bar{x} - \hat{\bar{x}}\|^2\} = E\{\|(\mathbf{A} - \mathbf{A}_K)\bar{y}\|^2\} \\ &= E\{[(\mathbf{A} - \mathbf{A}_K)\bar{y}]^T [(\mathbf{A} - \mathbf{A}_K)\bar{y}]\} \quad \mathbf{A}_K \text{补零成 } N \times N \text{ 阶矩阵} \\ &= E\{\bar{y}^T (\mathbf{A}^T - \mathbf{A}_K^T)(\mathbf{A} - \mathbf{A}_K)\bar{y}\}\end{aligned}$$


- 这里 $(\mathbf{A}^T - \mathbf{A}_K^T)(\mathbf{A} - \mathbf{A}_K)$ 只有右下角 $N-K$ 个对角元素为1，其余为0


- 故

$$\varepsilon = E\left\{\sum_{i=K+1}^N (y_i^2)\right\}$$


- $$\varepsilon = \sum_{i=K+1}^N \lambda_i$$

使用主分量描绘图像 (蓝, 绿, 红, 近红, 中红, 远红)







λ_1	λ_2	λ_3	λ_4	λ_5	λ_6
10344	2966	1401	203	94	31



（主分量投影后） 6幅对应的主分量图像



仅使用两个主分量重建的多光谱图像




重建图像与原图像的差（已经经过归一化图像增强显示），最后一幅热红外图像显示了最大的不同，原因是原始的热红外图像是有些模糊的。

用主分量对尺度、平移和旋转归一化

将区域内的点视为二维向量，进行主分量变换。

结果有两个方面：

1. 在总体的质心处建立了变换后的坐标中心；
2. 产生的y坐标是旋转后的形式。







$$\mathbf{m}_x = \begin{bmatrix} 3 \\ 3 \end{bmatrix}$$

$$\mathbf{C}_x = \begin{bmatrix} 3.333 & 2.00 \\ 2.00 & 3.333 \end{bmatrix}$$

$$\mathbf{e}_1 = \begin{bmatrix} 0.707 \\ 0.707 \end{bmatrix}$$

$$\mathbf{e}_2 = \begin{bmatrix} -0.707 \\ 0.707 \end{bmatrix}$$




能用于图像匹配的特征

- 特征点是图像特征的一种重要表示，可以通过设计使其具备良好的特性，实现目标识别、匹配和跟踪；
- 相比处理整幅图像，处理特征大大减少了计算量，在很多应用中已经足够；
- 目标上的特征点可以用于不同图像中的目标识别；
- 理想特征点应该满足平移、旋转、尺度和光照等的不变性。

Harris 角点

- 角是曲线方向的快速变化。
- 角点是高度有效的特征，因为他们对于视点独特且不变的。在立体匹配、自动跟踪等领域具有广泛的应用价值。
- 是否存在角点的分析



检测器在平坦区域（A），边缘区域（B）和角区（C）域移动时的方向性响应。

Harris角点检测器

- 移动前后，检测器窗口内图像灰度差的平方的加权和为：

$$C(x,y) = \sum_s \sum_t w(s,t) [f(s+x,t+y) - f(s,t)]^2$$

- 用泰勒展开 $f(s+x,t+y) \approx f(s,t) + xf_x(s,t) + yf_y(s,t)$

- 得到：
$$C(x,y) = \sum_s \sum_t w(s,t) [xf_x(s,t) + yf_y(s,t)]^2$$

- 用矩阵表示为：
$$C(x,y) = [x \ y] \mathbf{M} \begin{bmatrix} x \\ y \end{bmatrix}$$

- 其中：
$$\mathbf{M} = \sum_s \sum_t w(s,t) \mathbf{A} \quad , \quad \mathbf{A} = \begin{bmatrix} f_x^2 & f_x f_y \\ f_x f_y & f_y^2 \end{bmatrix}$$

Harris角点检测器

- M称为哈里斯矩阵，它是检测器窗口内所有像素A矩阵的加权和

$$\mathbf{M} = \sum_s \sum_t w(s,t) \mathbf{A} \quad \mathbf{A} = \begin{bmatrix} f_x^2 & f_x f_y \\ f_x f_y & f_y^2 \end{bmatrix}$$

- 权重矩阵可以有两种形式：1) 盒式滤波器；
- 2) 指数函数 $w(s,t) = e^{-(s^2+t^2)/2\sigma^2}$

如何区分边缘点和角点？

- 1) 两个小特征值表示几乎恒定的灰度；
- 1) 一个小和一个大特征值表示存在垂直或者水平边界；
- 3) 两个大特征值表示存在一个角或者孤立的亮点；




FIGURE 11.46 (a)–(c) Noisy images and image patches (small squares) encompassing image regions similar in content to those in Fig. 11.45. (d)–(f) Plots of value pairs (f_x, f_y) showing the characteristics of the eigenvalues of $\mathbf{M}$ that are useful for detecting the presence of a corner in an image patch.

角点响应测度

- 对于一个实对称正定矩阵D，有

$$\text{Tr}(\mathbf{H}) = D_{xx} + D_{yy} = \alpha + \beta$$

$$\text{Det}(\mathbf{H}) = D_{xx}D_{yy} - (D_{xy})^2 = \alpha\beta$$


- 因此定义角点响应测度为：

$$\begin{aligned} R &= \lambda_x \lambda_y - k(\lambda_x + \lambda_y)^2 \\ &= \det(\mathbf{M}) - k\text{trace}^2(\mathbf{M}) \end{aligned}$$

- K为一个设定的参数，为角点检测的“敏感因子”。推荐k=0.04。

Harris角点示例

- 噪声方差0.006;
- 参数 k 与角点阈值 T 联合决定了最终获得的角点;
- 两个参量作用有一定互补性




a b c
d e f

FIGURE 11.47 (a) A 600×600 image with values in the range $[0,1]$, corrupted by additive Gaussian noise with 0 mean and variance of 0.006. (b) Result of applying the HS corner detector with $k = 0.04$ and $T = 0.01$ (the defaults). Several errors are visible. (c) Result using $k = 0.1$ and $T = 0.01$. (d) Result using $k = 0.1$ and $T = 0.1$. (e) Result using $k = 0.04$ and $T = 0.1$. (f) Result using $k = 0.04$ and $T = 0.3$ (only the strongest corners on the left were detected).

Harris角点示例

- 噪声方差0.01;
- 不同 k 与 T 的结果



a b
c d

FIGURE 11.48

(a) Same as Fig. 11.47(a), but corrupted with Gaussian noise of mean 0 and variance 0.01.
(b) Result of using the HS detector with $k = 0.04$ and $T = 0.01$ [compare with Fig. 11.47(b)].
(c) Result with $k = 0.249$, (near the highest value in our implementation), and $T = 0.01$.
(d) Result of using $k = 0.04$ and $T = 0.15$.

Harris角点示例

- 通过调整 k 和 T 的值获得较好的检测结果。





FIGURE 11.49 600×600 image of a building. (b) Result of applying the HS corner detector with $k = 0.04$ and $T = 0.01$ (the default values in our implementation). Numerous irrelevant corners were detected. (c) Result using $k = 0.249$ and the default value for T . (d) Result using $k = 0.17$ and $T = 0.05$. (e) Result using the default value for k and $T = 0.05$. (f) Result using the default value of k and $T = 0.07$.

Harris角点的特性

- 平移不变性;
- 相对的旋转不变性;
- 无尺度不变性。



a b


FIGURE 11.50

(a) Image rotated 5°.

(b) Corners detected using the parameters used to obtain Fig. 11.49(f).

Harris 角点应用

- 特征提取
 - 相机标定
- 特征跟踪
 - KLT跟踪



最大稳定极值区域 (MSER)

- MSER产生稳定的“斑点”区域，便于在两幅或者多幅图像之间建立对应关系；
- 构建图像区域的分量树，树的每一级对应于一个分割阈值，树的每个节点表示一个定义如下的极值区域R：

$$\forall p \in R \text{ and } \forall q \in \text{boundary}(R) : I(p) > I(q)$$

- 极值区域R是I的一个区域，性质是这个区域内任意一点的灰度都高于该区域边界上任意一点的灰度。

最大稳定极值区域 (MSER)

- 通过分析分量树的节点可以求出MSER。
- 对树中的每个连通区域，计算稳定性测度：


$$\psi(R_j^{T+n\Delta T}) = \frac{|R_i^{T+(n-1)\Delta T}| - |R_k^{T+(n+1)\Delta T}|}{|R_j^{T+n\Delta T}|}$$

- MSER是对应于树中节点的区域，它在包含该区域的树的路径上具有局部极小测度的一个值。在实践中，意味着在两个 ΔT 相邻阈值处理后的图像之间没有发生明显变化的区域。

最大稳定极值区域 (MSER)

- $T=10, \Delta T=50$
- 实际中，由于光照、视点、噪声等变量引起的光强变化，稳定性因子很少为0.
- 控制检测到的MSER数量的方法是：1) 选择 ΔT ; 2) 约束区域的大小范围。

225	175	90	90
125	5	90	225
5	5	5	225
125	5	225	225



最大稳定极值区域 (MSER)


- $T=0, \Delta T=10$
- MSER尺寸限制在图像大小的3%~10%之间。

a b
c d

FIGURE 11.52

(a) 600×570 CT slice of a human head. (b) Image smoothed with a box kernel of size 15×15 elements. (c) A extremal region along the path of the tree containing one MSER.

(d) The MSER. (All MSER regions were limited to the range 10,260–34,200 pixels, corresponding to a range between 3% and 10% of image size.) (Original image courtesy of Dr. David R. Pickens, Vanderbilt University.)



MSER示例



FIGURE 11.53 (a) Building image of size 600×600 pixels. (b) Image smoothed using a 5×5 box kernel. (c) and (d) MSERs detected using $T = 0$, $\Delta T = 10$, and MSER size range between 10,000 and 30,000 pixels, corresponding approximately to 3% and 8% of the area of the image. (e) Composite image.

MSER检测效果 (旋转)



a b c

FIGURE 11.54 (a) Building image rotated 5° counterclockwise. (b) Smoothed image using the same kernel as in Fig. 11.53(b). (c) Composite MSER detected using the same parameters we used to obtain Fig. 11.53(e). The MSERs of the original and rotated images are almost identical.

MSER检测效果 (尺度缩放)


- 图像缩小后的MSER检测;
- 尺寸范围限定为原来的1/4



FIGURE 11.55 (a) Building image reduced to half-size. (b) Image smoothed with a 3×3 box kernel. (c) Composite MSER obtained with the same parameters as Fig. 11.53(e), but using a valid MSER region size range of 2,500—7,500 pixels.

MSER描述符构建与匹配

使其具备旋转和尺度不变性。



MSER应用

- 文本检测
- MSER匹配



尺度不变特征变换 (SIFT)

- David Lowe 【2004】 开发的著名特征点检测算法;
 - 是本课程目前为止最复杂的算法;
 - 具备优良的尺度、旋转、光照和视点不变性。
 - 在特征匹配、目标识别、运动跟踪、三维重建等很多方面具有十分广泛的应用。
-
- [1] Distinctive image features from scale-invariant keypoints. David G. Lowe, International Journal of Computer Vision, 60, 2 (2004), pp. 91-110



David G. Lowe
University of British Columbia,
Vancouver, B.C., Canada

基本步骤


- 1) 检测尺度空间极大值
 - 构建尺度空间; 构建高斯差分 (DOG) 金字塔; 检测局部极大值。
- 2) 提升关键点位置精度
 - 内插, 消除边缘相应;
- 3) 计算关键点方向
- 4) 计算关键点描述子
 - 梯度方向直方图

尺度空间

- SIFT中，用高斯核实现平滑，尺度参数是标准差：

$$L(x, y, \sigma) = G(x, y, \sigma) \star f(x, y)$$


- 其中 $G(x, y, \sigma) = \frac{1}{2\pi\sigma^2} e^{-(x^2+y^2)/2\sigma^2}$
- 一个倍频程对应的高斯核中，所用的值为 $k^s\sigma = 2\sigma$ ；对于 $s = 2, k = \sqrt{2}$ 。



尺度空间

FIGURE 11.57

Illustration using images of the first three octaves of scale space in SIFT. The entries in the table are values of standard deviation used at each scale of each octave. For example the standard deviation used in scale 2 of octave 1 is $k\sigma_1$, which is equal to 1.0. (The images of octave 1 are shown slightly overlapped to fit in the figure space.)



构建高斯差分(DOG)金字塔

- 高斯差分：

$$D(x, y, \sigma) = [G(x, y, k\sigma) - G(x, y, \sigma)] \star f(x, y)$$

$$\text{即 } D(x, y, \sigma) = L(x, y, k\sigma) - L(x, y, \sigma)$$

高斯差分是LOG的一个近似。在边缘检测中，LOG查找过零点，而此处DOG查找极值点。





FIGURE 11.58 How Eq. (11-69) is implemented in scale space. There are $s + 3$ $L(x, y, \sigma)$ images and $s + 2$ corresponding $D(x, y, \sigma)$ images in each octave.

在DOG中查找极值点

- 每个像素与其周围8个像素，以及与上下两层DOG的18个像素相比较，即必须是该27个像素中的极值（极大或极小），才能成为特征点候选。

FIGURE 11.59

Extrema (maxima or minima) of the $D(x, y, \sigma)$ images in an octave are detected by comparing a pixel (shown in black) to its 26 neighbors (shown shaded) in 3×3 regions at the current and adjacent scale images.



改进关键点精度

- 通过在候选点附近，对DOG拟合一个内插函数来提升关键点位置精度。

$$\begin{aligned} D(\mathbf{x}) &= D + \left(\frac{\partial D}{\partial \mathbf{x}}\right)^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T \frac{\partial}{\partial \mathbf{x}} \left(\frac{\partial D}{\partial \mathbf{x}}\right) \mathbf{x} \\ &= D + (\nabla D)^T \mathbf{x} + \frac{1}{2} \mathbf{x}^T \mathbf{H} \mathbf{x} \end{aligned}$$

- 其中
- $\nabla D = \frac{\partial D}{\partial \mathbf{x}} = \begin{bmatrix} \partial D / \partial x \\ \partial D / \partial y \\ \partial D / \partial \sigma \end{bmatrix}$, $\mathbf{H} = \begin{bmatrix} \partial^2 D / \partial x^2 & \partial^2 D / \partial x \partial y & \partial^2 D / \partial x \partial \sigma \\ \partial^2 D / \partial y \partial x & \partial^2 D / \partial y^2 & \partial^2 D / \partial y \partial \sigma \\ \partial^2 D / \partial \sigma \partial x & \partial^2 D / \partial \sigma \partial y & \partial^2 D / \partial \sigma^2 \end{bmatrix}$ 是海森矩阵
- 可求得极值位置为: $\hat{\mathbf{x}} = -\mathbf{H}^{-1}(\nabla D)$

消除边缘响应

- 计算DOG的局部曲折度，通过计算D的黑森矩阵

$$\mathbf{H} = \begin{bmatrix} \partial^2 D / \partial x^2 & \partial^2 D / \partial x \partial y \\ \partial^2 D / \partial y \partial x & \partial^2 D / \partial y^2 \end{bmatrix} = \begin{bmatrix} D_{xx} & D_{xy} \\ D_{yx} & D_{yy} \end{bmatrix}$$

有：

$$\text{Tr}(\mathbf{H}) = D_{xx} + D_{yy} = \alpha + \beta$$
$$\text{Det}(\mathbf{H}) = D_{xx}D_{yy} - (D_{xy})^2 = \alpha\beta$$

令： $\alpha = r\beta$ 则有：


$$\frac{[\text{Tr}(\mathbf{H})]^2}{\text{Det}(\mathbf{H})} = \frac{(\alpha + \beta)^2}{\alpha\beta} = \frac{(r\beta + \beta)^2}{r\beta^2} = \frac{(r + 1)^2}{r}$$

只需检查： $\frac{[\text{Tr}(\mathbf{H})]^2}{\text{Det}(\mathbf{H})} < \frac{(r + 1)^2}{r}$ 即可判定消除最大最小特征值之比大于r的点。



关键点方向

- 使用关键点的尺度来选定最接近该尺度的高斯平滑图像，计算 3σ 邻域内样本点的梯度方向形成；
- 方向采用36个容器覆盖360度范围；
- 添加到直方图中的每个样本按期梯度幅度和一个圆形高斯函数加权，标准差为关键点尺度的1.5倍。
 - 选定一个直方图中最大值为主方向。为了增强匹配的鲁棒性，只保留峰值大于主方向峰值80%的方向作为该关键点的辅方向。对于同一梯度值的多个峰值的关键点位置，在相同位置和尺度将会有多个关键点被创建但方向不同。仅有15%的关键点被赋予多个方向，
- 用抛物线拟合最接近每个峰的三个直方图值，对峰值位置进行内插来提升精度。




主方向计算示意，以8 bin为例
(实际采用36 bin)




关键点描述子

- 目前为止已经为关键点确定了图像位置、尺度和方向，为这三个变量提供了不变性；
- 下一步是为围绕每个不同的关键点的一个局部区域计算一个描述子，同时对尺度、方向、光照和图像视点的变换尽可能不变；
- 目的是能利用这些描述子来识别两幅或多幅图像中局部区域之间的匹配。




关键点描述子

- 在关键点周围 16×16 范围内的像素统计梯度方向；
- 用标准差为区域大小一半的高斯加权来分配权重，用于乘以每个点处的梯度幅度；
- 在每个 4×4 区域量化8个梯度方向进行统计。
- 统计时梯度方向进行内插运算，按比例在各个方向容器中分配贡献。
- 得到 $4 \times 4 \times 8 = 128$ 维描述向量。




关键点描述子的不变性

- 方向不变性：在计算描述子前，描述子的坐标和梯度方向相对于关键点方向进行了旋转；像素点梯度按行、列和方向进行插值分配贡献。
- 光照不变性：
 - 1) 描述子向量归一化，提供光照的仿射不变性；
 - 2) 对归一化特征向量进一步处理，降低较大梯度值的影响，使所有分量都小于实验确定值0.2（截断）。然后再重新归一化。应对相机饱和等导致的非线性光照变化。



主方向旋转




像素点梯度插值

SIFT算法小结

- 1) 构建尺度空间, 采用 $\sigma = 1.6$, $s = 2$ 和三个倍频程;
- 2) 得到初始关键点, 在DOG图像中查找极值;
- 3) 提高关键点位置的精度, 通过泰勒级数展开对初始关键点DOG值进行内插;
- 4) 滤除不合适的关键点, 删除低对比度 (阈值0.03) 和定位差的关键点 ($r=10$)
- 5) 计算关键点方向;
- 6) 计算关键点描述子。


SIFT例子

具备优良的匹配
正确性与旋转不
变性




SIFT例子

具备优良的
尺度不变性




SIFT特征的应用

- 将图像转变为局部特征，具备平移、旋转、尺度和光照不变性，用于图像匹配和识别。



利用SIFT实现3D 物体识别

- 分割获得提取物体轮廓



利用SIFT实现3D 物体识别


- 只需要最少3个特征点，更多的特征点提升可靠性。
- 由于采用仿射模型，因此三维形状并不特别准确，但对于识别足够。



利用SIFT实现遮挡环境下的物体识别



位置识别



几何估计与三维重构



Snaveley, Seitz, & Szeliski 2006

更多的特征点类型

- SURF (Speeded Up Robust Features, 64-vector) [1]
 - 比SIFT计算速度更快;
 - 采用海森矩阵提取极大值作为特征点;
 - 采用积分图和Haar 小波变换来对像素灰度进行编码。
- ORB(Oriented FAST and Rotated BRIEF) [2]
 - 基于改进的FAST特征检测器, 构造图像尺度金字塔生成描述子。
 - 经典的ORB-SLAM2就是以ORB特征为基础的
- 深度神经网络提取特征
 - Superpoint[3]

[1] Herbert Bay, Tinne Tuytelaars, and Luc Van Gool, **SURF: Speeded Up Robust Features**, ECCV 2006;

[2] Ethan Rublee Vincent Rabaud Kurt Konolige Gary Bradski, **ORB: an efficient alternative to SIFT or SURF**, ICCV 2011

[3] Daniel DeTone, Tomasz Malisiewicz, Andrew Rabinovich, **SuperPoint: Self-Supervised Interest Point Detection and Description**, CVPR 2018

大作业报告

- 请提前在学在浙大系统报名，截止时间6月27日
- 请做好PPT，每人报告时间控制在10分钟左右；
- 在考试周结束前上传大作业书面报告和PPT。
- 根据课堂报告，大作业书面报告和PPT等情况确定加分（1~5分）。
- 若还有课后书面作业和编程作业没有交的，请尽快补交，平时成绩占40%。

作业

- **书面作业：**

- 11.2, 11.13, 11.21, 11.24, 11.27, 11.32

- **上机作业（三选一）：**

- 1.对一个简单二值图像的边缘，实现边界追踪，并获取其链码表示；
- 2.对一幅灰度图像，实现对灰度共生矩阵的计算。
- 3.对一幅灰度图像，实现Harris 角点的提取。